



---

## Biblio Stage

---

BALOT Louise

28 Mai 2026

IRIT - APO

## Table des matières

|          |                                                                                    |           |
|----------|------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Assimilation de données</b>                                                     | <b>2</b>  |
| 1.1      | Définition des variables et des espaces . . . . .                                  | 2         |
| 1.2      | Formulation Bayésienne . . . . .                                                   | 2         |
| 1.3      | L'hypothèse Gaussienne et la fonction de coût . . . . .                            | 3         |
| 1.4      | Résolution et calcul du Gain Optimal (BLUE) . . . . .                              | 3         |
| 1.5      | Calcul de la covariance d'erreur d'analyse ( $P^a$ ) . . . . .                     | 4         |
| 1.6      | Méthodes séquentielles et cohérence des notations . . . . .                        | 4         |
| 1.7      | Algorithme du Filtre de Kalman . . . . .                                           | 4         |
| <b>2</b> | <b>Le Filtre de Kalman d'Ensemble (EnKF)</b>                                       | <b>5</b>  |
| 2.1      | L'EnKF stochastique et ses propriétés algébriques . . . . .                        | 5         |
| 2.2      | L'EnKF déterministe (Filtres racine carrée) . . . . .                              | 6         |
| 2.3      | Algorithme de l'EnKF . . . . .                                                     | 7         |
| 2.4      | Comparaison et critères de choix entre EnKF stochastique et déterministe . . . . . | 8         |
| 2.5      | Correction des erreurs d'échantillonnage : localisation et inflation . . . . .     | 9         |
| 2.5.1    | Localisation de covariance (Espace du modèle) . . . . .                            | 9         |
| 2.5.2    | Localisation par analyse locale (Espace des observations) . . . . .                | 10        |
| 2.5.3    | Le problème des observations satellites non-locales . . . . .                      | 10        |
| <b>3</b> | <b>modèle NPZ 1D</b>                                                               | <b>10</b> |
| <b>4</b> | <b>Espaces de Hilbert à Noyau Reproductible (RKHS)</b>                             | <b>11</b> |
| 4.1      | L'équivalence entre fonctions noyaux et RKHS . . . . .                             | 11        |
| 4.2      | Le Théorème du Représentant . . . . .                                              | 12        |
| <b>5</b> | <b>Extension aux méthodes à noyaux et gestion des contraintes</b>                  | <b>13</b> |
| 5.1      | ETKF . . . . .                                                                     | 14        |
| 5.2      | Généralisation et résolution avec des noyaux : le Kernel ETKF . . . . .            | 15        |
| 5.2.1    | Généralisation au KETKF : Le cas idéal des observations complètes ( $H = I$ )      | 16        |
| 5.2.2    | Le cas général : observations partielles ( $H \neq I$ ) . . . . .                  | 17        |
| 5.3      | Résolution opérationnelle du Kernel-ETKF . . . . .                                 | 18        |
| 5.3.1    | Calcul du vecteur de poids optimal $\alpha^*$ . . . . .                            | 18        |
| 5.3.2    | Mise à jour de la moyenne de l'ensemble . . . . .                                  | 19        |
| 5.3.3    | Mise à jour de la covariance et reconstruction de l'ensemble . . . . .             | 19        |
| 5.3.4    | Génération de l'ensemble et gestion du rang de la covariance . . . . .             | 19        |
| 5.3.5    | Synthèse : Algorithme global de l'étape d'analyse KETKF . . . . .                  | 20        |
| <b>6</b> | <b>Expériences numériques</b>                                                      | <b>22</b> |
| 6.1      | Modèle de Lorenz 63 . . . . .                                                      | 22        |
| 6.2      | Expériences . . . . .                                                              | 22        |
| 6.3      | Le fléau de la dimension : Analyse sur le Lorenz-96 . . . . .                      | 23        |
| <b>7</b> | <b>Méthodo expériences</b>                                                         | <b>23</b> |

# 1 Assimilation de données

L'assimilation de données est une méthode "prédicteur/correction". Une prévision, calculée au pas de temps précédent et valable à l'instant considéré, est utilisée comme prédicteur (l'ébauche). Les observations disponibles permettent de corriger cette ébauche pour estimer au mieux l'état réel du système étudié.

## 1.1 Définition des variables et des espaces

### L'espace d'état (dimension $n$ )

Il contient tous les vecteurs liés à la physique du modèle numérique. Dans les modèles géophysiques réels, la dimension  $n$  (Nombre de variables  $\times$  Nombre de points de grille) est souvent gigantesque.

- $x_t$  : le vecteur d'état vrai (*true state*), inconnu en pratique.
- $x_b$  : le vecteur d'ébauche (*background*), qui est l'estimation de  $x_t$  fournie par le modèle avant la prise en compte des observations.
- $e_b$  : l'erreur d'ébauche ( $e_b = x_b - x_t$ ). On suppose qu'elle est sans biais ( $\mathbb{E}[e_b] = 0$ ). Sa matrice de covariance d'erreur est notée  $P^b = \mathbb{E}[e_b e_b^T]$ , de taille  $(n \times n)$ .
- $x_a$  : le vecteur d'analyse (*analysis*), qui est l'état corrigé après assimilation.
- $P^a$  : la matrice de covariance d'erreur d'analyse associée à  $x_a$ , de taille  $(n \times n)$ .

### L'espace des observations (dimension $p$ )

Il contient les informations issues des capteurs (satellites, bouées, etc.). Généralement, le réseau d'observation est très lacunaire comparé à la résolution du modèle ( $p \ll n$ ).

- $y$  : le vecteur des observations.
- $H$  : l'opérateur d'observation, une fonction (souvent matricielle de taille  $p \times n$ ) qui projette l'espace d'état vers l'espace des observations pour permettre la comparaison.

Les mesures étant imparfaites, on définit le modèle d'observation :

$$y = Hx_t + e_0 \quad (1)$$

où  $e_0$  est le vecteur d'erreur de mesure, supposé sans biais ( $\mathbb{E}[e_0] = 0$ ), de matrice de covariance  $R = \mathbb{E}[e_0 e_0^T]$  de taille  $(p \times p)$ . On fait également l'hypothèse classique que les erreurs du modèle et des instruments sont décorrélées ( $\mathbb{E}[e_b e_0^T] = 0$ ).

## 1.2 Formulation Bayésienne

Puisque le modèle et les instruments de mesure comportent des incertitudes, on se place dans un cadre probabiliste. L'objectif est de trouver l'état  $x$  le plus probable sachant que l'on a mesuré  $y$ . Cette probabilité conditionnelle est donnée par la **règle de Bayes** :

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} \quad (2)$$

Chaque terme a une signification physique précise :

- $p(x)$  est la **densité a priori** : elle représente l'information contenue dans l'ébauche  $x_b$ .
- $p(y|x)$  est la **vraisemblance** : c'est la probabilité d'obtenir la mesure  $y$  sachant un état  $x$  donné.
- $p(x|y)$  est la **densité a posteriori** : c'est le résultat de l'assimilation, contenant toute l'information fusionnée.

### 1.3 L'hypothèse Gaussienne et la fonction de coût

Pour manipuler la règle de Bayes sur un ordinateur, on fait une hypothèse mathématique forte : on suppose que les erreurs d'ébauche et d'observation suivent des **lois normales gaussiennes**. L'important avantage des lois gaussiennes est qu'elles s'expriment à l'aide d'exponentielles :

$$p(x) \propto \exp \left( -\frac{1}{2}(x - x_b)^T (P^b)^{-1} (x - x_b) \right) \quad (3)$$

$$p(y|x) \propto \exp \left( -\frac{1}{2}(y - Hx)^T R^{-1} (y - Hx) \right) \quad (4)$$

En injectant ces lois dans l'équation de Bayes, les probabilités se multiplient et leurs exposants s'additionnent. Pour trouver l'état optimal (celui qui maximise la probabilité *a posteriori*  $p(x|y)$ ), on applique la fonction  $-\ln$ .

Maximiser Bayes revient donc strictement à minimiser la **fonction de coût**  $J(x)$  suivante (approche variationnelle / moindres carrés) :

$$J(x) = \underbrace{\frac{1}{2}(x - x_b)^T (P^b)^{-1} (x - x_b)}_{\text{Pénalité d'ébauche}} + \underbrace{\frac{1}{2}(y - Hx)^T R^{-1} (y - Hx)}_{\text{Pénalité d'observation}} \quad (5)$$

### 1.4 Résolution et calcul du Gain Optimal (BLUE)

Pour trouver l'état d'analyse  $x_a$  qui minimise cette erreur totale, on calcule le gradient de  $J(x)$  et on cherche le point où il s'annule ( $\nabla J(x_a) = 0$ ) :

$$\nabla J(x_a) = (P^b)^{-1}(x_a - x_b) - H^T R^{-1}(y - Hx_a) = 0 \quad (6)$$

En ajoutant et en soustrayant le terme  $Hx_b$  dans la parenthèse de droite, on fait apparaître l'**innovation**  $(y - Hx_b)$ , qui mesure l'écart entre la mesure réelle et la prévision du modèle :

$$\begin{aligned} (P^b)^{-1}(x_a - x_b) &= H^T R^{-1} [(y - Hx_b) - H(x_a - x_b)] \\ \left[ (P^b)^{-1} + H^T R^{-1} H \right] (x_a - x_b) &= H^T R^{-1} (y - Hx_b) \end{aligned}$$

En isolant  $x_a$ , on aboutit à l'équation fondamentale de correction :

$$x_a = x_b + K(y - Hx_b) \quad (7)$$

où  $K$  est appelé le **gain de Kalman**, exprimé par :

$$K = \left[ (P^b)^{-1} + H^T R^{-1} H \right]^{-1} H^T R^{-1} \quad (8)$$

Cette écriture nécessite d'inverser une matrice dans l'espace d'état ( $n \times n$ ), ce qui est impossible en grande dimension. En appliquant l'identité matricielle de Sherman-Morrison-Woodbury, on obtient la forme pratique du gain :

$$K = P^b H^T (H P^b H^T + R)^{-1} \quad (9)$$

L'inversion se fait désormais dans l'espace des observations (dimension  $p$ ), ce qui rend le calcul possible.

## 1.5 Calcul de la covariance d'erreur d'analyse ( $P^a$ )

Une fois l'état corrigé  $x_a$  obtenu, il est crucial d'évaluer sa fiabilité mathématique. D'où provient l'incertitude sur l'analyse? On la déduit en calculant l'erreur véritable de l'analyse  $e_a = x_a - x_t$ . En remplaçant  $x_a$  par sa formule (7) et  $y$  par  $Hx_t + e_0$ , on obtient la propagation des erreurs :

$$\begin{aligned} e_a &= (x_b + K(y - Hx_b)) - x_t \\ e_a &= x_b - x_t + K(Hx_t + e_0 - Hx_b) \\ e_a &= e_b - KH(x_b - x_t) + Ke_0 \\ e_a &= (I - KH)e_b + Ke_0 \end{aligned}$$

L'erreur d'analyse est donc une combinaison linéaire de l'erreur d'ébauche et de l'erreur d'observation. En passant à l'espérance mathématique  $P^a = \mathbb{E}[e_a e_a^T]$ , et en utilisant l'hypothèse que  $e_b$  et  $e_0$  sont décorrélés, on obtient la forme dite de *Joseph* :

$$P^a = (I - KH)P^b(I - KH)^T + K R K^T \quad (10)$$

Si le gain  $K$  utilisé est le gain optimal défini à l'équation (9), de nombreuses simplifications matricielles opèrent et la formule se réduit à sa forme classique :

$$P^a = (I - KH)P^b \quad (11)$$

Cette équation montre que l'assimilation d'une observation réduit mathématiquement l'incertitude initiale (puisque l'on soustrait la matrice définie positive  $KHP^b$  à  $P^b$ ).

## 1.6 Méthodes séquentielles et cohérence des notations

Les méthodes séquentielles permettent de résoudre le problème d'assimilation de données dans le temps. Elles alternent entre deux étapes à chaque instant  $t_k$  : une étape de **prévision** (propagation de l'état par le modèle dynamique) et une étape d'**analyse** pour corriger cette prévision.

### Évolution des notations dans un cadre temporel (Filtre de Kalman) :

Dans le cycle séquentiel, l'ébauche  $x_b$  n'est plus statique : elle est fournie par la prévision du modèle issue de l'analyse précédente. Pour refléter cette dynamique temporelle, les notations évoluent :

- L'ébauche  $x_b$  devient  $x_k^f$  (pour *forecast*).
- La covariance d'ébauche  $P^b$  devient  $P_k^f$ .
- L'analyse  $x_a$  et sa covariance  $P^a$  deviennent  $x_k^a$  et  $P_k^a$ .

On modélise ainsi l'évolution du système et les observations par :

$$\begin{cases} x_{k+1}^t = M_{k+1}(x_k^t) + v_{k+1} \\ y_k = H_k(x_k^t) + e_k^0 \end{cases}$$

Où  $M_{k+1}$  est l'opérateur du modèle dynamique (qui fait passer de  $t_k$  à  $t_{k+1}$ ), et  $v_{k+1}$  est l'erreur inhérente au modèle (imperfections de la physique, discrétisation), associée à la matrice de covariance  $Q_k = \mathbb{E}[v_k v_k^T]$ .

## 1.7 Algorithme du Filtre de Kalman

On suppose ici que les opérateurs  $H_k$  et  $M_k$  sont linéaires (ou linéarisés) et que les erreurs sont sans biais. L'algorithme se déroule comme suit :

### 1. Initialisation ( $k = 0$ )

- Estimer l'état initial :  $x_0^f$
- Estimer sa matrice de covariance d'erreur :  $P_0^f$

## 2. Boucle sur les temps d'observation $t_k$

### a. Étape d'Analyse

— Calcul du gain optimal (méthode BLUE) :

$$K_k = P_k^f H_k^T (H_k P_k^f H_k^T + R_k)^{-1}$$

— Estimation de l'état analysé :

$$x_k^a = x_k^f + K_k(y_k - H_k x_k^f)$$

— Mise à jour de la matrice de covariance d'analyse :

$$P_k^a = (I - K_k H_k) P_k^f$$

### b. Étape de Prévision (vers $t_{k+1}$ )

— Prévision du nouvel état :

$$x_{k+1}^f = M_{k+1} x_k^a$$

— Prévision de la matrice de covariance d'erreur :

$$P_{k+1}^f = M_{k+1} P_k^a M_{k+1}^T + Q_k$$

## 2 Le Filtre de Kalman d'Ensemble (EnKF)

Le Filtre de Kalman classique est limité car stocker et propager la matrice de covariance  $P$  ( $n \times n$ ) dépasse la mémoire des ordinateurs. L'EnKF résout ce problème en abandonnant les formules théoriques de propagation de la covariance pour passer à une approche statistique de Monte-Carlo.

On fait tourner un échantillon de  $N$  modèles en parallèle (les membres de l'ensemble). La matrice de covariance devient implicite, elle est calculée directement à partir des écarts de ce nuage de modèles autour de sa moyenne (la matrice d'anomalies  $X$ ).

Ainsi, pour coder l'EnKF de manière efficace, on adopte une formulation matricielle. On pose : la matrice contenant tous les membres en prévision

$$E^f = [x_1^f, \dots, x_N^f] \in \mathbb{R}^{n \times N}$$

et la matrice de leurs anomalies centrées

$$X^f = [x_1^f - \hat{\mu}_f, \dots, x_N^f - \hat{\mu}_f] \in \mathbb{R}^{n \times N}$$

avec  $\hat{\mu}_f = \frac{1}{N} \sum_{i=1}^N (x_i^f)$ ; et de même pour  $E^a, X^a$ .

Par ailleurs, en statistiques, la matrice de covariance empirique d'un échantillon s'estime (sans biais) en multipliant la matrice de ses écarts à la moyenne par sa transposée, divisée par  $N - 1$ . Ainsi, les matrices de covariance d'ébauche et d'analyse s'écrivent :

$$\hat{P}^f = \frac{1}{N-1} X^f (X^f)^T \quad \text{et} \quad \hat{P}^a = \frac{1}{N-1} X^a (X^a)^T$$

On définit aussi :

$$\hat{K} = \hat{P}^f H^T [H \hat{P}^f H^T + \hat{R}]^{-1}$$

Il existe deux grandes façons de mettre à jour cet ensemble lors de l'analyse :

### 2.1 L'EnKF stochastique et ses propriétés algébriques

L'EnKF stochastique, introduit par Evensen (1994), repose sur une idée simple : appliquer les équations du filtre de Kalman standard individuellement à chaque membre de l'ensemble.

## L'astuce des observations perturbées

Burgers (1998) a démontré que pour que la variance de l'ensemble après analyse reste cohérente avec la théorie, il faut traiter les observations comme des variables aléatoires. En pratique, à partir du vecteur d'observation réel  $y \in \mathbb{R}^p$ , on génère un ensemble d'observations perturbées pour chaque membre  $i$  :

$$y_i = y + \epsilon_i, \quad 1 \leq i \leq N \quad (12)$$

où  $\epsilon_i \sim \mathcal{N}(0, R)$  est un bruit blanc gaussien. Si on définit la matrice des anomalies d'observations  $A_y = [\epsilon_1, \dots, \epsilon_N] \in \mathbb{R}^{p \times N}$ , la matrice de covariance empirique des erreurs de mesure s'écrit :

$$\hat{R} = \frac{1}{N-1} A_y A_y^T \quad (13)$$

Lorsque la taille de l'ensemble  $N$  tend vers l'infini,  $\hat{R}$  converge exactement vers la matrice  $R$  du filtre de Kalman classique. Chaque membre est ensuite mis à jour indépendamment :

$$x_i^a = x_i^f + \hat{K}[y_i - Hx_i^f] \quad (14)$$

d'où

$$\hat{\mu}^a = \hat{\mu}^f + \hat{K}[\bar{y} - H\hat{\mu}^f] \quad (15)$$

## Optimisation algorithmique et espace de l'ensemble

Le passage à la formulation globale repose sur une simplification algébrique du gain de Kalman  $\hat{K}$  en utilisant les expressions établies en 2 et l'équation 13. En posant  $S^f = HX^f \in \mathbb{R}^{p \times N}$  (la projection des anomalies dans l'espace des observations), on obtient :

$$\hat{K} = X^f (S^f)^T \left[ S^f (S^f)^T + A_y A_y^T \right]^{-1}$$

En injectant ce gain dans la mise à jour simultanée de tous les membres ( $E^a = E^f + \hat{K}[Y - HE^f]$ ), l'équation globale de l'ensemble s'écrit :

$$E^a = E^f + X^f (S^f)^T \left[ S^f (S^f)^T + A_y A_y^T \right]^{-1} [Y - HE^f] \quad (16)$$

Cette formulation montre que la matrice de covariance géante  $\hat{P}^f$  (de taille  $n \times n$ ) n'est **jamais calculée explicitement**. On manipule uniquement des matrices de taille  $p \times N$ . Comme dans les applications géophysiques la dimension d'état est immense par rapport au nombre d'observations et de membres ( $n \gg p > N$ ), la complexité numérique est drastiquement réduite.

De plus, en utilisant le fait que la matrice des anomalies  $X^f$  est centrée sur ses colonnes ( $X^f e = 0$ , avec  $e$  un vecteur de 1), l'équation (16) peut se factoriser sous la forme :

$$E^a = E^f T_{stoch} \quad (17)$$

où  $T_{stoch} \in \mathbb{R}^{N \times N}$  est une matrice de transformation. Cette relation finale est très importante : elle prouve mathématiquement que l'ensemble après analyse ( $E^a$ ) est confiné dans le sous-espace engendré par l'ensemble de prévision ( $E^f$ ). L'analyse ne crée pas de nouvelles dimensions physiques, elle se contente de recalculer une combinaison linéaire optimale des membres existants.

## 2.2 L'EnKF déterministe (Filtres racine carrée)

La conclusion de la méthode stochastique montre que l'analyse se résume à appliquer une matrice de transformation  $T$  à l'ensemble. Cependant, cette matrice dépend de  $A_y$  et introduit donc une erreur d'échantillonnage due au bruit aléatoire.

Pour éviter cette erreur, on utilise les versions déterministes de l'EnKF. L'idée principale de l'ETKF (*Ensemble Transform Kalman Filter*) est de poser la relation  $E^a = E^f T$ , et de chercher à mettre à jour la moyenne et les anomalies de l'ensemble en respectant exactement la variance *a posteriori* théorique, sans jamais générer d'observations perturbées.

## Détermination de T

En écrivant l'équation de mise à jour de la covariance sous sa forme ensembliste avec les expressions en 2, on obtient avec  $S^f = HX^f \in \mathbb{R}^{p \times N}$  :

$$P_k^a = (I - K_k H_k) P_k^f \implies (X^a)(X^a)^T = (X^f) \left[ I_N - (S^f)^T (S^f (S^f)^T + R)^{-1} S^f \right] (X^f)^T \quad (18)$$

En supposant  $(S^f (S^f)^T + R)$  inversible.

## L'astuce de Woodbury (Changement d'espace)

Le terme central demande d'inverser une matrice dans l'espace des observations (dimension  $p$ ). Si le nombre d'observations est très grand ( $p > N$ ), ce calcul devient lourd et la matrice peut être singulière. En appliquant la formule de Sherman-Morrison-Woodbury, on bascule le calcul dans l'espace de l'ensemble (dimension  $N \times N$ ) :

$$(X^a)(X^a)^T = (X^f) \left[ I_N + (S^f)^T R^{-1} S^f \right]^{-1} (X^f)^T \quad (19)$$

## L'astuce de la racine carrée symétrique (Élimination du biais)

La matrice centrale  $A = I_N + (S^f)^T R^{-1} S^f$  est réelle et symétrique. On peut donc calculer sa décomposition en valeurs propres (EVD) :  $A = U \Sigma U^T$ . Si on cherche simplement à isoler  $X^a$  en prenant la racine carrée de l'inverse, on pourrait écrire :

$$X^a = X^f U \Sigma^{1/2} \quad (20)$$

Cependant, Sakov et Oke (2008) ont montré que cette formulation de base introduit un biais : la nouvelle matrice d'anomalies  $X^a$  n'est plus centrée sur zéro (sa moyenne n'est plus nulle), ce qui fausse les statistiques. Pour régler ce problème, on utilise la **racine carrée symétrique** en remultipliant par  $U^T$  à droite :

$$X^a = X^f U \Sigma^{1/2} U^T \quad (21)$$

Cette astuce technique est fondamentale car elle garantit mathématiquement que les anomalies analysées restent centrées sur zéro, préservant ainsi l'intégrité physique du modèle.

## Le trick de la rotation aléatoire

Pour éviter que l'ensemble ne s'appauvrisse au cours du temps et pour rapprocher la distribution d'une forme gaussienne, on peut multiplier le résultat par une matrice aléatoire orthogonale  $\Phi^T$  (générée par l'algorithme de Pham, 2001) :

$$X^a = X^f U \Sigma^{1/2} U^T \Phi^T \quad (22)$$

Comme  $\Phi^T$  est orthogonale, elle modifie l'orientation du nuage de points pour lui redonner du réalisme sans changer la valeur de la variance globale.

## 2.3 Algorithme de l'EnKF

### 1. Initialisation ( $k = 0$ )

- Estimer l'état moyen initial :  $x_0^f$
- Estimer la matrice de covariance initiale :  $P_0^f$
- Créer un ensemble de  $N$  membres  $\{x_{0,i}^f\}_{i=1}^N$  échantillonnés autour de  $x_0^f$  selon la covariance  $P_0^f$ .



## 2. Boucle sur les temps d'observation $t_k$

### Étape d'Analyse

#### — Si le filtre est stochastique :

- Génération des observations perturbées :  $y_{k,i} = y_k + \epsilon_{k,i}$  avec  $\epsilon_{k,i} \sim \mathcal{N}(0, R_k)$
- Calcul du gain empirique :  $K_k = P_k^f H_k^T (H_k P_k^f H_k^T + R_k)^{-1}$
- Mise à jour de chaque membre :  $x_{k,i}^a = x_{k,i}^f + K_k(y_{k,i} - H_k(x_{k,i}^f))$

#### — Si le filtre est déterministe (ETKF) :

- Mise à jour de la moyenne seule :  $\bar{x}_k^a = \bar{x}_k^f + K_k(y_k - H_k(\bar{x}_k^f))$
- Équation de transformation des anomalies par EVD :  $X^a = X^f U \Sigma^{-1/2} U^T$
- Reconstitution de l'ensemble analysé :  $x_{k,i}^a = \bar{x}_k^a + X_i^a$

### c. Étape de Prévision (vers $t_{k+1}$ )

- Propagation de chaque membre par le modèle non-linéaire  $M$ , en y ajoutant une perturbation aléatoire  $v_{k+1,i}$  issue de la covariance d'erreur modèle  $Q$  :

$$x_{k+1,i}^f = M_{k+1}(x_{k,i}^a) + v_{k+1,i}$$

- L'état prévu est la moyenne du nouvel ensemble :  $\bar{x}_{k+1}^f = \frac{1}{N} \sum_{i=1}^N x_{k+1,i}^f$
- Calcul de la nouvelle matrice de covariance de prévision empirique :

$$P_{k+1}^f = \frac{1}{N-1} \sum_{i=1}^N (x_{k+1,i}^f - \bar{x}_{k+1}^f)(x_{k+1,i}^f - \bar{x}_{k+1}^f)^T$$

## Comportement face à la non-gaussianité

L'étape d'analyse de l'EnKF est linéaire, ce qui signifie qu'elle n'est pas optimale si la distribution de l'ensemble n'est pas gaussienne après l'étape de prévision. C'est un point critique pour le modèle biologique NPZ, dont les dynamiques sont fortement non-linéaires. Néanmoins, comme la correction est appliquée membre par membre pour la version stochastique, l'EnKF a l'avantage de préserver par construction certaines propriétés non-gaussiennes de la distribution *a priori*, même si l'analyse linéaire a tendance à rapprocher la distribution finale d'une forme gaussienne.

## 2.4 Comparaison et critères de choix entre EnKF stochastique et déterministe

Le choix entre la version stochastique et la version déterministe de l'EnKF dépend d'un compromis entre la taille de l'ensemble, la précision des mesures et la forme de la distribution.

### Précision pour les petits ensembles ( $N$ petit)

L'EnKF déterministe produit des analyses plus précises lorsque la taille de l'ensemble  $N$  est restreinte. Dans la version stochastique, le fait de rajouter des perturbations aléatoires sur les observations introduit un **erreur d'échantillonnage** supplémentaire (le terme résiduel  $Z$  dans l'Équation 1.39 de la thèse). Dans la version déterministe, comme on ne perturbe pas les observations, ce terme résiduel est nul. L'analyse déterministe est donc mathématiquement plus efficace et plus stable à budget informatique réduit (faible valeur de  $N$ ).

### Robustesse face à la non-gaussianité

Bien qu'aucun des deux filtres ne soit mathématiquement "robuste" face à des données aberrantes (car la mise à jour repose uniquement sur la moyenne et la covariance), leurs comportements diffèrent en cas de forte contamination non-gaussienne :

- **Le déterministe est plus rigide** : Il impose strictement la covariance théorique du filtre de Kalman. Si une donnée aberrante apparaît après l'étape de prévision, elle va fortement biaiser tous les moments d'ordre supérieur de l'ensemble.
- **Le stochastique est plus souple** : Grâce à l'introduction des perturbations aléatoires sur les mesures, il donne une chance aux données aberrantes d'être en partie compensées et lissées par le hasard du tirage. L'EnKF stochastique se montre donc plus performant et plus stable lorsque la distribution *a priori* est fortement non-gaussienne ou lorsque l'erreur d'observation  $R$  est très faible.

## Le dilemme de la taille de l'ensemble $N$

La mise en œuvre pratique du filtre impose de choisir la taille  $N$  de l'ensemble selon un double enjeu :

- **Précision** : L'erreur d'approximation de type Monte-Carlo diminue en  $1/\sqrt{N}$ . Plus  $N$  est grand, plus l'estimation est proche de la solution exacte.
- **Coût informatique** : La complexité de l'algorithme grandit linéairement avec  $N$ , car il faut propager chaque membre individuellement.

Dans le cadre de ce stage, l'objectif de l'implémentation en langage Julia sera de trouver le compromis optimal : identifier la taille  $N$  minimale permettant de capturer les dynamiques fortement non-linéaires du modèle NPZ 1D sans surcharger le temps de calcul.

## 2.5 Correction des erreurs d'échantillonnage : localisation et inflation

Comme la taille de l'ensemble  $N$  est toujours très petite par rapport à la dimension du modèle ( $N \ll n$ ), l'estimation empirique de la covariance introduit de grandes erreurs d'échantillonnage. Le filtre a alors tendance à voir des **corrélations parasites** (des faux liens statistiques entre des points physiquement très éloignés), ce qui peut entraîner l'effondrement de l'ensemble et la divergence du filtre. Pour stabiliser le système, deux techniques sont indispensables : la localisation et l'inflation.

### L'inflation (Lutte contre la divergence du filtre)

À cause du faible nombre de membres, l'EnKF a naturellement tendance à sous-estimer l'erreur de sa prévision. Au fil des cycles d'assimilation, les membres de l'ensemble ont tendance à trop se rapprocher les uns des autres : le nuage de modèles se contracte et la variance s'effondre. Le filtre devient alors trop "sûr de lui" et finit par ignorer complètement les nouvelles observations. C'est ce qu'on appelle la **divergence du filtre**.

Pour éviter ce phénomène, on utilise l'inflation multiplicative. Avant l'étape d'analyse, on écarte artificiellement les membres de l'ensemble en multipliant la matrice des anomalies  $X^f$  par un facteur d'inflation  $\lambda$  légèrement supérieur à 1 :

$$X^f \leftarrow \sqrt{\lambda} X^f, \quad \text{avec } \lambda > 1 \quad (23)$$

Ce trick mathématique redonne de la dispersion à l'ensemble, ce qui force le Filtre de Kalman à rester attentif aux observations et évite qu'il ne plante.

### 2.5.1 Localisation de covariance (Espace du modèle)

Cette méthode consiste à modifier directement la matrice de covariance d'erreur du modèle via un produit de Schur (produit terme à terme, noté  $\circ$ ) avec une matrice de corrélation locale  $C$  :

$$\hat{P}_C^f = \hat{P}^f \circ C \quad (24)$$

Pour construire  $C$ , on utilise généralement la **fonction de Gaspari-Cohn**. C'est une fonction rationnelle par morceaux de degré 5 qui ressemble à une loi normale, mais à support compact : elle décroît en

fonction de la distance  $h$  et s'annule strictement au-delà d'une distance seuil ( $h \geq 2R$ ). Cette méthode réduit drastiquement l'erreur, mais elle est difficile à appliquer aux filtres d'ensemble classiques car ils ne manipulent pas explicitement la matrice de covariance globale.

### 2.5.2 Localisation par analyse locale (Espace des observations)

Cette approche consiste à mettre à jour chaque point de la grille du modèle indépendamment, en ne regardant que les observations situées dans une fenêtre spatiale locale autour de lui. C'est la méthode utilisée par le **LETKF** (*Local Ensemble Transform Kalman Filter*).

Pour éviter des cassures brutales sur le vecteur d'état aux bords de la fenêtre, le LETKF augmente artificiellement la variance de la matrice d'erreur d'observation  $R$  en fonction de la distance. Plus l'observation est loin du point à mettre à jour, plus son erreur  $R$  est grande, ce qui diminue progressivement son influence lors de l'analyse. Cette méthode est très puissante car elle est intrinsèquement parallélisable.

### 2.5.3 Le problème des observations satellites non-locales

Dans le cas d'une assimilation faible (très courante en géophysique), les deux méthodes de localisation donnent des résultats identiques. Le choix se fait donc sur des critères pratiques.

La localisation par analyse locale (LETKF) est idéale pour le calcul haute performance, mais elle souffre d'une limite majeure : elle exige que les observations soient locales pour pouvoir calculer une distance physique entre un point du modèle et une mesure. Or, dans le cas de ton modèle NPZ, les données proviennent souvent de satellites (réflectance, couleur de l'eau) qui intègrent des informations non-locales.

Pour résoudre ce problème, des approches récentes (comme Farchi et Bocquet, 2019) proposent de construire un **ensemble augmenté**  $\tilde{X}^f$  de taille  $\tilde{N} > N$  en utilisant des méthodes de modulation ou des décompositions en valeurs singulières (SVD) tronquées. Cet ensemble augmenté permet de mimer une localisation de covariance (espace modèle) tout en conservant l'efficacité algorithmique des méthodes ensemblistes. Cela devient alors possible d'assimiler efficacement les données des satellites.

## 3 modèle NPZ 1D

Afin d'évaluer les performances des filtres de Kalman à noyaux, nous nous intéressons à un modèle simplifié d'écosystème marin : le modèle Nutriments-Phytoplancton-Zooplancton. Celui-ci modélise la dynamique de la base de la chaîne trophique marine à travers trois variables d'état (exprimées en concentration de biomasse, par exemple en  $\text{mmol N m}^{-3}$ ) :

- $N$  : Les Nutriments (azote, phosphore...), dissous dans l'eau.
- $P$  : Le Phytoplancton (algues microscopiques), qui consomme les nutriments par photosynthèse.
- $Z$  : Le Zooplancton (animaux microscopiques), qui se nourrit du phytoplancton.

### Dynamique biologique (Le terme source)

L'évolution temporelle de ces trois compartiments est régie par un système d'équations différentielles ordinaires décrivant les interactions prédateur-proie et le recyclage de la matière. Une formulation classique s'écrit :

$$\begin{cases} \frac{dN}{dt} = -\mu_P(N)P + \gamma_Z Z + m_P P + m_Z Z \\ \frac{dP}{dt} = \mu_P(N)P - g_Z(P)Z - m_P P \\ \frac{dZ}{dt} = \beta g_Z(P)Z - m_Z Z - \gamma_Z Z \end{cases} \quad (25)$$

Où les fonctions de croissance et de broutage (*grazing*) sont **fortement non-linéaires**. Par exemple, l'assimilation des nutriments suit souvent une cinétique de Michaelis-Menten :  $\mu_P(N) = \mu_{max} \frac{N}{K_N + N}$ , et le broutage une réponse fonctionnelle de Holling :  $g_Z(P) = g_{max} \frac{P}{K_P + P}$ . Les termes  $m_P$  et  $m_Z$  représentent les mortalités,  $\beta$  l'efficacité d'assimilation et  $\gamma_Z$  l'excrétion.

## Extension spatiale 1D (Colonne d'eau)

Dans un cadre océanographique 1D, on s'intéresse à l'évolution de ces concentrations sur la verticale (la profondeur  $z$ ). Le modèle biologique est alors couplé à un modèle de transport physique (advection-diffusion). Si l'on note  $C \in \{N, P, Z\}$  la concentration d'un traceur, l'équation aux dérivées partielles (EDP) s'écrit :

$$\frac{\partial C}{\partial t} = \underbrace{\frac{\partial}{\partial z} \left( \kappa_z \frac{\partial C}{\partial z} \right)}_{\text{Mélange turbulent}} - \underbrace{w_c \frac{\partial C}{\partial z}}_{\text{Chute (sédimentation)}} + \underbrace{S_C(N, P, Z)}_{\text{Terme biologique NPZ}} \quad (26)$$

où  $\kappa_z$  est le coefficient de diffusion turbulente verticale et  $w_c$  la vitesse de chute (non nulle principalement pour le phytoplancton mort ou les détritus).

Ce modèle illustre parfaitement les limites de l'EnKF classique :

1. **Non-linéarité extrême** : Les fonctions de Michaelis-Menten et les multiplications entre variables d'état (ex :  $g_Z(P) \times Z$ ) créent des dynamiques chaotiques et des distributions non-gaussiennes.
2. **Contrainte de positivité** : Par définition physique, les concentrations  $N$ ,  $P$  et  $Z$  doivent rester strictement positives. Une mise à jour linéaire de l'EnKF peut générer des valeurs aberrantes ( $P < 0$ ), entraînant une instabilité numérique fatale lors de l'intégration du modèle au pas de temps suivant.

C'est dans ce cadre précis que l'apport des méthodes à noyaux et des RKHS, capables de traiter ces non-linéarités tout en imposant des contraintes lors de l'inversion de la pré-image, s'avère pertinent.

## 4 Espaces de Hilbert à Noyau Reproductif (RKHS)

Soit  $\mathcal{X}$  un ensemble arbitraire et  $\mathcal{H}$  un espace de Hilbert de fonctions définies sur  $\mathcal{X}$ . On dit que  $\mathcal{H}$  est un **espace de Hilbert à noyau reproductif** (RKHS) si, pour tout  $x \in \mathcal{X}$ , la forme linéaire d'évaluation :

$$\begin{aligned} L_x : \mathcal{H} &\longrightarrow \mathbb{R} \\ f &\longmapsto f(x) \end{aligned}$$

est continue. D'après le **théorème de représentation de Riesz**, la continuité de cette forme implique qu'il existe un unique élément  $k_x \in \mathcal{H}$  (noté aussi  $k(x, \cdot)$ ) tel que :

$$f(x) = \langle f, k(x, \cdot) \rangle_{\mathcal{H}}, \quad \forall f \in \mathcal{H} \quad (27)$$

L'Équation 27 est appelée la **propriété de reproduction** : elle signifie que le produit scalaire dans  $\mathcal{H}$  permet de *reproduire* la valeur de la fonction  $f$  en n'importe quel point  $x$ .

On définit alors le noyau reproductif complet comme la fonction  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  par :

$$k(x, y) = \langle k(x, \cdot), k(y, \cdot) \rangle_{\mathcal{H}} \quad (28)$$

### 4.1 L'équivalence entre fonctions noyaux et RKHS

Il existe une correspondance parfaite (une bijection) entre l'ensemble des fonctions noyaux et l'ensemble des RKHS. Cette relation repose sur deux résultats fondamentaux.

## 1. De la fonction noyau au RKHS (Théorème de Moore-Aronszajn)

Si on possède une fonction noyau  $k$  (symétrique et semi-définie positive), le théorème de Moore-Aronszajn garantit qu'il existe un **unique** espace de Hilbert de fonctions pour lequel  $k$  est son noyau reproduisant. Cela montre qu'à chaque noyau correspond un espace mathématique bien précis.

## 2. Du RKHS à la fonction noyau

Réciproquement, si on part d'un RKHS noté  $\mathcal{F}$  de noyau  $k$ , on peut prouver que  $k$  possède nécessairement les propriétés d'une fonction noyau :

— **La symétrie** : Pour tout  $(x, y) \in \mathcal{X}^2$ , la symétrie du produit scalaire donne directement :

$$k(x, y) = \langle k(x, \cdot), k(y, \cdot) \rangle_{\mathcal{F}} = \langle k(y, \cdot), k(x, \cdot) \rangle_{\mathcal{F}} = k(y, x)$$

— **La semi-définition positive** : Soit un ensemble de points  $(x_i)_{i=1}^d$  et un vecteur de poids  $\alpha \in \mathbb{R}^d$ . En construisant la fonction  $f = \sum_{i=1}^d \alpha_i k(x_i, \cdot)$ , on a  $f \in \mathcal{F}$  et on peut développer la forme quadratique associée à la matrice de Gram  $K$  :

$$\begin{aligned} \alpha^T K \alpha &= \sum_{i=1}^d \sum_{j=1}^d \alpha_i \alpha_j k(x_i, x_j) \\ &= \sum_{i=1}^d \sum_{j=1}^d \alpha_i \alpha_j \langle k(x_i, \cdot), k(x_j, \cdot) \rangle_{\mathcal{F}} \\ &= \left\langle \sum_{i=1}^d \alpha_i k(x_i, \cdot), \sum_{j=1}^d \alpha_j k(x_j, \cdot) \right\rangle_{\mathcal{F}} = \|f\|_{\mathcal{F}}^2 \geq 0 \end{aligned}$$

Une matrice de Gram est donc toujours semi-définie positive car sa forme quadratique s'identifie à la norme carrée d'une fonction dans le RKHS.

## 4.2 Le Théorème du Représentant

Le **Théorème du Représentant** est l'outil central qui rend les méthodes à noyaux applicables sur ordinateur. Il permet de réduire un problème d'optimisation de dimension infinie (recherche d'une fonction dans un espace fonctionnel  $\mathcal{F}$ ) à un problème de dimension finie (recherche de coefficients vectoriels).

### Théorème

Soit  $\mathcal{F}$  un RKHS de noyau  $k$ . On cherche à minimiser une fonction de coût globale  $Q(f)$  de la forme :

$$Q(f) = C(y, x_1, \dots, x_d, f(x_1), \dots, f(x_d)) + J(\|f\|_{\mathcal{F}}^2) \quad (29)$$

où  $C$  est une fonction de coût quelconque et  $J$  est une fonction de pénalité strictement croissante. Si un minimum  $f^* \in \mathcal{F}$  existe, alors il appartient obligatoirement au sous-espace de dimension finie engendré par les données :

$$f^* \in \text{Vect}(\{k(x_i, \cdot)\}_{i=1}^d) \quad (30)$$

### Démonstration

Le sous-espace  $V = \text{Vect}(\{k(x_i, \cdot)\}_{i=1}^d)$  étant de dimension finie, il est fermé. On peut donc décomposer l'espace de Hilbert complet sous la forme d'une somme directe avec son complémentaire orthogonal :  $\mathcal{F} = V \oplus V^\perp$ .

Tout candidat à la solution  $f^*$  s'écrit de manière unique comme la somme de sa projection sur l'espace des données  $u \in V$  et d'une composante orthogonale  $v \in V^\perp$  :

$$f^* = u + v$$

Évaluons la valeur de cette fonction en un point de donnée  $x_i$  en utilisant la propriété de reproduction :

$$\begin{aligned} f^*(x_i) &= \langle f^*, k(x_i, \cdot) \rangle_{\mathcal{F}} \\ &= \langle u + v, k(x_i, \cdot) \rangle_{\mathcal{F}} \\ &= \langle u, k(x_i, \cdot) \rangle_{\mathcal{F}} + \underbrace{\langle v, k(x_i, \cdot) \rangle_{\mathcal{F}}}_{=0 \text{ car } v \in V^\perp} = u(x_i) \end{aligned}$$

Comme  $f^*(x_i) = u(x_i)$  pour tous les points de données, la composante perpendiculaire  $v$  n'a aucune influence sur le calcul de la fonction de coût :

$$C(y, \dots, f^*(x_1), \dots) = C(y, \dots, u(x_1), \dots)$$

Regardons maintenant l'impact de cette décomposition sur le terme de pénalité. D'après le théorème de Pythagore, la norme carrée s'écrit :

$$\|f^*\|_{\mathcal{F}}^2 = \|u\|_{\mathcal{F}}^2 + \|v\|_{\mathcal{F}}^2 \geq \|u\|_{\mathcal{F}}^2$$

Comme la fonction de régularisation  $J$  est strictement croissante, on a  $J(\|f^*\|_{\mathcal{F}}^2) \geq J(\|u\|_{\mathcal{F}}^2)$ , avec une égalité stricte si et seulement si  $v = 0$ .

En combinant les deux morceaux, on obtient que  $Q(f^*) \geq Q(u)$ . Pour que  $f^*$  soit le minimum absolu de la fonction de coût, il est donc mathématiquement obligatoire que sa composante orthogonale soit nulle ( $v = 0$ ), ce qui prouve que  $f^* = u \in V$ .

## 5 Extension aux méthodes à noyaux et gestion des contraintes

Les modèles d'écosystèmes marins, tels que les modèles NPZ sont régis par des dynamiques fortement non-linéaires. L'application directe de l'analyse linéaire de l'EnKF classique dans l'espace physique est souvent sous-optimale et peut mener à des aberrations physiques (comme des concentrations négatives).

### Le principe de la projection et l'astuce du noyau

Pour pallier ce problème, l'approche par méthodes à noyaux propose de projeter l'état physique  $x \in \mathcal{X}$  vers un espace de Hilbert de très grande dimension  $\mathcal{H}$  via une application *feature map*  $\Phi$  :

$$x \in \mathcal{X} \longmapsto \Phi(x) \in \mathcal{H}$$

L'intuition sous-jacente est que les relations complexes et non-linéaires dans l'espace physique tendent à s'approcher d'un comportement linéaire dans ce nouvel espace  $\mathcal{H}$ , rendant le filtre de Kalman (optimal en linéaire) de nouveau performant. Puisque le calcul explicite en dimension infinie est impossible, on utilise **l'astuce du noyau** (*Kernel Trick*). Un noyau défini positif  $k$  permet de calculer le produit scalaire, et donc les covariances dans  $\mathcal{H}$ , en évaluant uniquement les états physiques :

$$k(x_i, x_j) = \langle \Phi(x_i), \Phi(x_j) \rangle_{\mathcal{H}}$$

## Le Filtre de Kalman d'Ensemble à Noyaux

Dans cette variante, l'algorithme d'analyse (le calcul du BLUE) est exécuté virtuellement dans le RKHS. Les calculs matriciels massifs se simplifient drastiquement et ne dépendent plus que de la **matrice de Gram** (de taille  $N \times N$ , où  $N$  est la taille de l'ensemble), dont les coefficients sont les évaluations  $k(x_i, x_j)$ . À l'issue de l'analyse, on obtient un état corrigé dans l'espace de Hilbert, noté  $\Phi^a \in \mathcal{H}$ .

### 5.1 ETKF

L'ETKF (*Ensemble Transform Kalman Filter*), introduit par Bishop et al. (2001), repose sur une formulation variationnelle du problème d'assimilation. L'idée fondamentale est de **restreindre la recherche de l'état analysé au sous-espace affine engendré par les membres de l'ensemble de prévision**.

Au lieu de chercher un état dans l'espace physique de dimension  $n$ , on paramétrise la moyenne analysée  $\hat{\mu}^a$  par un vecteur de poids  $w \in \mathbb{R}^N$  :

$$\hat{\mu}^a = \hat{\mu}^f + X^f w \quad (31)$$

où  $\hat{\mu}^f$  est la moyenne de prévision et  $X^f \in \mathbb{R}^{n \times N}$  est la matrice des anomalies.

### Le problème d'optimisation

On rappelle la fonction de coût d'un filtre de Kalman comme étant :

$$J(x) = \frac{1}{2}(x - \mu^f)^T (P^f)^{-1} (x - \mu^f) + \frac{1}{2}(y - Hx)^T R^{-1} (y - Hx) \quad (32)$$

En posant le changement de variable  $x = \hat{\mu}^f + X^f w$ , avec  $w \in \mathbb{R}^N$ , le terme de droite de l'équation 32 s'écrit

$$\frac{1}{2} \|y - H\hat{\mu}^f - HX^f w\|_{R^{-1}}^2$$

Par ailleurs, en prenant en compte le fait que  $P^f$  n'est pas souvent de rang plein, on utilise la décomposition en SVD de  $X^f$  pour exprimer sa pseudo inverse :

$$X^f = U \Sigma V^T$$

On a donc

$$P^f = \frac{1}{N-1} X^f X^{fT} = \frac{1}{N-1} U \Sigma^2 U^T$$

de pseudo inverse

$$P^{f\dagger} = (N-1) U \Sigma^{-2} U^T$$

Le terme de gauche s'exprime donc

$$\frac{1}{2} (X^f w)^T P^{f\dagger} (X^f w) = \frac{1}{2} (w^T V \Sigma U^T) P^{f\dagger} (U \Sigma V^T w) = \frac{N-1}{2} w^T w$$

Le problème d'assimilation se reformule alors comme la minimisation de la fonction de coût  $J(w)$  32 dans l'espace de dimension réduite  $N$  :

$$\arg \min_{w \in \mathbb{R}^N} J(w) = \frac{N-1}{2} \|w\|_2^2 + \frac{1}{2} \|y - H\hat{\mu}^f - HX^f w\|_{R^{-1}}^2 \quad (33)$$

Afin d'alléger les notations, on normalise les grandeurs par rapport à la matrice de covariance d'erreur d'observation  $R$ . On définit l'innovation normalisée  $e_d \in \mathbb{R}^p$  et la matrice des anomalies projetées  $\tilde{H} \in \mathbb{R}^{p \times N}$  :

$$\begin{aligned} e_d &= R^{-1/2}(y - H\hat{\mu}^f) \\ \tilde{H} &= R^{-1/2}HX^f \end{aligned}$$

Afin d'obtenir le problème d'assimilation suivant :

$$J(w) = \frac{N-1}{2}\|w\|_2^2 + \frac{1}{2}\|e_d - \tilde{H}w\|_2^2 \quad (34)$$

### Résolution pour la moyenne et les anomalies

La condition d'optimalité du premier ordre ( $\nabla J(w) = 0$ ) permet d'obtenir explicitement le vecteur de poids optimal  $w^*$  :

$$w^* = \left[ (N-1)I_N + \tilde{H}^T \tilde{H} \right]^{-1} \tilde{H}^T e_d \quad (35)$$

Ce vecteur permet de calculer la nouvelle moyenne de l'ensemble analysé :  $\hat{\mu}^a = \hat{\mu}^f + X^f w^*$ .

et la covariance d'analyse s'écrit :

$$\begin{aligned} \hat{P}_w^a &= (\nabla^2 J(w^*))^{-1} \\ \hat{P}^a &= X^f (\nabla^2 J(w^*))^{-1} (X^f)^T \end{aligned}$$

Pour reconstruire la nouvelle matrice d'anomalies  $X^a$  telle que  $X^a(X^a)^T = (N-1)\hat{P}^a$ , on extrait analytiquement la racine carrée matricielle de cette expression :

$$X^a = \sqrt{N-1} X^f (\nabla^2 J(w^*))^{-1/2} \quad (36)$$

L'état d'un membre individuel  $x_i^a$  se met à jour :

$$x_i^a = \hat{\mu}^a + (X^a)_i$$

Avec :

$$\nabla^2 J(w^*) = (N-1)I_N + \tilde{H}^T \tilde{H} \quad (37)$$

En posant  $S = \frac{1}{\sqrt{N-1}}\tilde{H}$ , la matrice des anomalies analysées  $X^a$  s'obtient par une transformation linéaire appliquée aux anomalies de prévision ( $X^a = X^f T$ ) avec :

$$T = (I_N + S^T S)^{-1/2} \quad (38)$$

On retrouve l'architecture déterministe de l'ETKF : une matrice de transformation  $T$  de taille  $N \times N$ , calculée sans perturbation des observations, garantissant une estimation optimale de la variance de l'ensemble analysé.

## 5.2 Généralisation et résolution avec des noyaux : le Kernel ETKF

L'équation de coût de l'ETKF classique repose sur une minimisation aux moindres carrés pénalisée (une régression Ridge sur les poids de l'ensemble).

Considérons un problème de régression Ridge classique où l'on cherche un vecteur de paramètres  $\beta \in \mathbb{R}^n$  pour prédire des observations  $y \in \mathbb{R}^p$  à partir d'une matrice de données  $X \in \mathbb{R}^{p \times n}$  :

$$\arg \min_{\beta \in \mathbb{R}^n} J(\beta) = \frac{1}{2}\|X\beta - y\|_2^2 + \frac{1}{2}\|\beta\|_2^2 \quad (39)$$



En notant  $x_i^T$  la  $i$ -ème ligne de la matrice  $X$  (correspondant à la  $i$ -ème observation  $y_i$ ), on peut réécrire cette fonction de coût sous forme de somme :

$$\arg \min_{\beta \in \mathbb{R}^n} J(\beta) = \frac{1}{2} \sum_{i=1}^p (x_i^T \beta - y_i)^2 + \frac{1}{2} \beta^T \beta$$

On remarque que les variables n'interviennent que sous la forme de produits scalaires euclidiens. On peut introduire la fonction noyau linéaire définie par  $\kappa(z, t) = z^T t$ . L'équation devient alors :

$$J(\beta) = \frac{1}{2} \sum_{i=1}^p (\kappa(x_i, \beta) - y_i)^2 + \frac{1}{2} \kappa(\beta, \beta)$$

### Le passage à la dimension infinie (RKHS)

En utilisant la **propriété de reproduction** de l'espace de Hilbert  $\mathcal{H}_\kappa$ , on remplace le vecteur  $\beta$  par une fonction abstraite  $f \in \mathcal{H}_\kappa$ . Le problème n'est plus limité au noyau linéaire, il s'étend à n'importe quel noyau :

$$\arg \min_{f \in \mathcal{H}_\kappa} \hat{J}(f) = \frac{1}{2} \sum_{i=1}^p (f(x_i) - y_i)^2 + \frac{1}{2} \|f\|_{\mathcal{H}_\kappa}^2 \quad (40)$$

Nous sommes passés d'une recherche vectorielle en dimension  $n$  à une recherche fonctionnelle en dimension potentiellement infinie.

Pour rendre ce problème calculable par un ordinateur, on applique le **Théorème du Représentant**. Il garantit que la fonction optimale  $f^*$  appartient au sous-espace engendré par le noyau évalué sur les  $d$  points de données :

$$f^*(\cdot) = \sum_{j=1}^p \alpha_j \kappa(\cdot, x_j)$$

En injectant cette forme paramétrique paramétrée par le vecteur  $\alpha \in \mathbb{R}^d$  dans la fonction de coût, on obtient :

$$\arg \min_{\alpha \in \mathbb{R}^p} \tilde{J}(\alpha) = \frac{1}{2} \sum_{i=1}^p \left( y_i - \sum_{j=1}^p \alpha_j \kappa(x_i, x_j) \right)^2 + \frac{1}{2} \left\| \sum_{i=1}^p \alpha_i \kappa(\cdot, x_i) \right\|_{\mathcal{H}_\kappa}^2$$

Le dernier terme (la norme de la fonction dans le RKHS) se simplifie magiquement grâce à la linéarité du produit scalaire et à la propriété de reproduction en  $\alpha^T K \alpha$  où  $K \in \mathbb{R}^{p \times p}$  est la matrice de Gram dont les éléments sont  $K_{ij} = \kappa(x_i, x_j)$ .

La fonction de coût finale, purement matricielle, s'écrit alors :

$$\arg \min_{\alpha \in \mathbb{R}^p} \tilde{J}(\alpha) = \frac{1}{2} \|y - K\alpha\|_2^2 + \frac{1}{2} \alpha^T K \alpha \quad (41)$$

Cette démonstration prouve qu'un problème d'optimisation initialement formulé dans l'espace physique (sur  $\beta$ ) peut être entièrement transposé et résolu dans l'espace des données (sur  $\alpha$ ) à l'aide d'une simple matrice de Gram  $K$ . C'est très exactement cette mécanique de transposition qui est appliquée pour transformer l'ETKF classique en Kernel-ETKF.

#### 5.2.1 Généralisation au KETKF : Le cas idéal des observations complètes ( $H = I$ )

Considérons d'abord le cas théorique idéal où toutes les variables du modèle physique sont observées ( $H = I$ ).

Dans ce contexte, la matrice des anomalies projetées  $\tilde{H}$  se réduit simplement aux anomalies de l'ensemble normalisées. En partant de la fonction de coût classique de l'ETKF de l'équation 34, et par

analogie avec le problème de Regression Ridge précédent, le problème devient non-linéaire, résoluble par inversion matricielle dans l'espace de l'ensemble :

$$\arg \min_{\alpha \in \mathbb{R}^N} \tilde{J}(\alpha) = \frac{N-1}{2} \alpha^T K \alpha + \frac{1}{2} \|e_d - K \alpha\|_2^2 \quad (42)$$

### 5.2.2 Le cas général : observations partielles ( $H \neq I$ )

Dans les applications réelles (comme pour le modèle NPZ),  $p \ll n$ . Si l'on applique la formulation précédente uniquement sur les variables observées, les variables non-observées ne seront pas mises à jour.

Pour résoudre ce problème de transfert d'information entre l'espace observé et l'espace caché, on utilise la stratégie d'augmentation d'état d'Evensen (2006). L'idée est de construire un vecteur d'état étendu contenant à la fois l'état physique complet et sa projection dans l'espace des observations.

L'équation de mise à jour de l'ensemble (moyenne et anomalies) s'écrit alors sous la forme de matrices superposées basées sur l'équation 36 :

$$\begin{bmatrix} E^a \\ H E^a \end{bmatrix} = \begin{bmatrix} \hat{\mu}^f \\ H \hat{\mu}^f \end{bmatrix} + \begin{bmatrix} X^f \\ H X^f \end{bmatrix} w + \sqrt{N-1} (P_{aug}^a)^{1/2} \quad (43)$$

avec la matrice de covariance analysée augmentée :

$$P_{aug}^a = \begin{bmatrix} P_{XX}^a & P_{XH}^a \\ (P_{XH}^a)^T & P_{HH}^a \end{bmatrix} \quad (44)$$

**L'avantage algorithmique :** Cette astuce mathématique permet de calculer les poids optimaux  $w$  en résolvant le problème RKHS uniquement dans le bloc inférieur (l'espace des observations), puis d'appliquer ce même vecteur  $w$  à la matrice des anomalies physiques  $X^f$  (le bloc supérieur). Les variables non-observées sont ainsi corrigées de manière physiquement cohérente grâce aux corrélations implicites portées par les membres de l'ensemble.

### Généralisation par noyaux : Proposition de la fonction de coût

L'astuce du vecteur d'état augmenté permet de formuler mathématiquement le problème du Kernel-ETKF. En combinant cette extension spatiale avec le formalisme des méthodes à noyaux, on obtient la proposition suivante :

**Proposition :** Le problème d'optimisation de l'ETKF se généralise dans un Espace de Hilbert à Noyau Reproductif (RKHS) par la minimisation suivante :

$$\arg \min_{\alpha \in \mathbb{R}^{n+p}} \tilde{J}(\alpha) = \frac{N-1}{2} \alpha^T K \alpha + \frac{1}{2} \|e_d - \Pi_H K \alpha\|_2^2 \quad (45)$$

Cette équation repose sur deux objets matriciels fondamentaux travaillant dans l'espace augmenté (de dimension  $n+p$ ) :

- $\Pi_H = \begin{bmatrix} 0_{n \times n} & 0_{n \times p} \\ 0_{p \times n} & I_p \end{bmatrix} \in \mathbb{R}^{(n+p) \times (n+p)}$  est la matrice de projection. Elle agit comme un masque qui "éteint" la partie physique du vecteur pour ne conserver que la partie observable lors du calcul de l'erreur avec l'innovation  $e_d$ .
- $K = \begin{bmatrix} K_X & K_{XH} \\ K_{XH}^T & K_H \end{bmatrix} \in \mathbb{R}^{(n+p) \times (n+p)}$  est la matrice de Gram globale (la matrice de noyau). Elle est subdivisée en blocs :
  - $K_X \in \mathbb{R}^{n \times n}$  : le noyau appliqué aux variables d'état (les colonnes de  $X^f$ ).
  - $K_H \in \mathbb{R}^{p \times p}$  : le noyau appliqué aux anomalies projetées (les colonnes de  $\tilde{H}$ ).
  - $K_{XH} \in \mathbb{R}^{n \times p}$  : le **noyau croisé**, qui est le moteur physique de l'algorithme, capturant les dépendances non-linéaires entre l'état caché de l'océan et les observations.

### Démonstration par le Théorème du Représentant

Pour démontrer cette formulation, on part de la fonction de coût de l'ETKF (Équation 33) que l'on transpose dans un espace de Hilbert  $\mathcal{H}_\kappa$  de noyau reproduisant  $\kappa$ . En utilisant la propriété de reproduction, la recherche du vecteur de poids  $w$  devient la recherche d'une fonction  $f \in \mathcal{H}_\kappa$  :

$$\arg \min_{f \in \mathcal{H}_\kappa} \hat{J}(f) = \frac{N-1}{2} \|f\|_{\mathcal{H}_\kappa}^2 + \frac{1}{2} \sum_{i=1}^p \left( f(\tilde{h}_i) - e_{d,i} \right)^2 \quad (46)$$

C'est ici qu'intervient l'extension de l'ensemble. Pour s'assurer que la fonction solution mette à jour les variables non-observées, on définit notre ensemble de "points de données" comme l'union des anomalies physiques  $x_i^f$  et des anomalies observées  $\tilde{h}_i$ .

D'après le Théorème du Représentant, la fonction optimale  $f^*$  cherchée en dimension infinie appartient nécessairement au sous-espace engendré par le noyau évalué sur *tous* ces points de données. On peut donc la paramétrer par un vecteur dual  $\alpha$  de dimension  $n+p$  :

$$f^*(\cdot) = \sum_{i=1}^n \alpha_i \kappa(\cdot, x_i^f) + \sum_{j=1}^p \alpha_{n+j} \kappa(\cdot, \tilde{h}_j) \quad (47)$$

En injectant cette forme paramétrique dans l'équation de coût fonctionnelle, et en utilisant les propriétés algébriques de la norme dans le RKHS ( $\|f\|_{\mathcal{H}_\kappa}^2 = \alpha^T K \alpha$ ), on retombe exactement sur la formulation matricielle de l'équation (45). Le problème abstrait en dimension infinie est ainsi rigoureusement réduit à la recherche d'un vecteur de coefficients  $\alpha \in \mathbb{R}^{n+p}$ .

### 5.3 Résolution opérationnelle du Kernel-ETKF

La généralisation de la fonction de coût dans l'espace augmenté via le Théorème du Représentant permet d'obtenir des formules de résolution explicites pour la mise à jour de la moyenne et de la covariance de l'ensemble.

#### 5.3.1 Calcul du vecteur de poids optimal $\alpha^*$

Le problème (Équation 45) est un problème aux moindres carrés linéaires. La condition d'optimalité du premier ordre annule son gradient vis-à-vis du vecteur étendu  $\alpha \in \mathbb{R}^{n+p}$  :

$$\begin{aligned} (N-1)K\alpha - (\Pi_H K)^T (e_d - \Pi_H K \alpha) &= 0 \\ K[(N-1)I_{n+p} + \Pi_H^T \Pi_H K] \alpha &= K \Pi_H^T e_d \end{aligned}$$

Puisque  $\Pi_H$  est une matrice de projection orthogonale vers l'espace des observations ( $\Pi_H^T \Pi_H = \Pi_H$ ), la résolution de ce système linéaire donne la solution optimale  $\alpha^*$ . De manière remarquable, l'action du masque  $\Pi_H$  annule strictement la composante physique du vecteur :

$$\alpha^* = \begin{bmatrix} \alpha_X^* \\ \alpha_H^* \end{bmatrix} = \begin{bmatrix} 0_n \\ [(N-1)I_p + K_H]^{-1} e_d \end{bmatrix} \quad (48)$$

Cette propriété algébrique est fondamentale pour les performances de l'algorithme : bien que paramétrée mathématiquement dans l'espace augmenté de dimension  $n+p$ , l'inversion matricielle ne requiert en pratique que la résolution d'un système symétrique semi-défini positif de dimension  $p$  (le nombre d'observations).

### 5.3.2 Mise à jour de la moyenne de l'ensemble

Dans le RKHS, la fonction optimale permettant de calculer la nouvelle moyenne s'évalue à l'aide du vecteur  $\alpha^*$ . Par analogie avec le cas linéaire de l'ETKF, la moyenne d'ensemble analysée  $\hat{\mu}^a \in \mathbb{R}^n$  se calcule en projetant la solution duale  $\alpha^*$  à l'aide du noyau. Puisque la partie  $\alpha_X^*$  est nulle, la correction ne dépend que du **noyau croisé**  $K_{XH}$  :

$$\hat{\mu}^a = \hat{\mu}^f + K_{XH}\alpha_H^* \quad (49)$$

$$\hat{\mu}^a = \hat{\mu}^f + K_{XH}[(N-1)I_p + K_H]^{-1}e_d \quad (50)$$

L'information contenue dans l'innovation des observations ( $e_d$ ) est ainsi propagée à l'ensemble des variables d'état (même non-observées) via les relations de corrélation non-linéaires capturées par  $K_{XH}$ .

### 5.3.3 Mise à jour de la covariance et reconstruction de l'ensemble

Pour finaliser l'étape d'analyse du filtre, il est nécessaire de reconstruire les membres individuels de l'ensemble. Dans le cadre de l'estimation variationnelle, la matrice de covariance de l'analyse  $P^a$  est proportionnelle à la pseudo-inverse de la matrice Hessienne de la fonction de coût :

$$\nabla^2 \tilde{J} = (N-1)K + K\Pi_H\Pi_H K \implies P^a \propto K \left[ \nabla^2 \tilde{J} \right]^+ K \quad (51)$$

L'inversion numérique directe d'une telle matrice de taille  $(n+p) \times (n+p)$  est non seulement extrêmement coûteuse, mais sujette à de sévères instabilités si la matrice de Gram  $K$  est singulière.

Pour contourner ce problème, on exploite la décomposition en valeurs propres (EVD) de la matrice de noyau d'observation  $K_H = U_H \Sigma_H U_H^T$  (où  $\Sigma_H = \text{diag}(\lambda_1, \dots, \lambda_p)$  contient les valeurs propres), et en appliquant systématiquement l'identité matricielle de Woodbury, le bloc physique  $P_X^a \in \mathbb{R}^{n \times n}$  de la covariance analysée s'exprime par :

$$P_X^a = \frac{1}{N-1} \left[ K_X - K_{XH} U_H \text{diag} \left( \frac{1}{(N-1) + \lambda_i} \right) U_H^T K_{XH}^T \right] \quad (52)$$

Cette formule élégante constitue un atout algorithmique majeur : elle ne nécessite **aucune inversion numérique risquée**. La pénalité  $(N-1)$  agit naturellement comme un terme de régularisation (type régression de Tikhonov) sur les valeurs propres  $\lambda_i$ , garantissant la robustesse du calcul.

Enfin, pour générer la nouvelle matrice d'anomalies de l'ensemble  $X^a$ , il suffit d'extraire la racine carrée matricielle de  $P_X^a$  en utilisant une décomposition en valeurs singulières tronquée, assurant la mise à jour de la dispersion de l'ensemble avant de lui rajouter la nouvelle moyenne  $\hat{\mu}^a$ .

### 5.3.4 Génération de l'ensemble et gestion du rang de la covariance

L'étape finale du KETKF consiste à générer les  $N$  nouveaux membres de l'ensemble analysé  $x_i^a$ . Puisque la matrice de covariance  $P_X^a$  a été obtenue de manière purement analytique, il faut en extraire les anomalies. Pour ce faire, on calcule sa décomposition en valeurs propres (EVD) que l'on tronque à son rang  $r_\Sigma$  (en ne gardant que les valeurs propres strictement positives) :

$$P_X^a \approx \tilde{U} \tilde{\Sigma} \tilde{U}^T \quad (53)$$

La matrice "racine" des anomalies s'écrit alors  $\tilde{U} \tilde{\Sigma}^{1/2}$  et possède  $r_\Sigma$  colonnes. Or, pour relancer le cycle de prévision du filtre, le modèle numérique exige de recevoir **exactement**  $N$  membres. Selon la valeur du rang  $r_\Sigma$  par rapport à la taille de l'ensemble  $N$ , trois cas de figure se présentent pour ajuster les dimensions de la matrice d'anomalies sans altérer ses propriétés statistiques.

#### Cas 1 : Déficit de rang ( $r_\Sigma < N$ )

Ce cas se produit souvent avec des modèles de petite dimension ou avec un noyau purement linéaire.

La matrice d'anomalies manque de colonnes. Si l'on se contentait de la compléter avec des zéros, l'ensemble s'appauvrirait artificiellement. Il faut donc augmenter le nombre de colonnes tout en préservant strictement la covariance empirique et en garantissant une moyenne nulle. On utilise pour cela une matrice de rotation spécifique  $W \in \mathbb{R}^{r_\Sigma \times N}$  (proposée par Farchi & Bocquet, 2019). L'équation de mise à jour des membres devient :

$$x_i^a = \hat{\mu}^a + \sqrt{N-1} \left[ \tilde{U} \tilde{\Sigma}^{1/2} W \right]_i \quad \forall i \in \{1, \dots, N\} \quad (54)$$

*Note : le facteur  $\sqrt{N-1}$  provient de la définition classique de la covariance empirique  $\hat{P} = \frac{1}{N-1} X X^T$ , qui impose  $X = \sqrt{N-1} \hat{P}^{1/2}$ .*

### Cas 2 : Excès de rang ( $r_\Sigma > N$ )

C'est le cas typique lors de l'utilisation de noyaux non-linéaires de rang plein (comme le noyau Gaussien RBF) ou en présence de méthodes de localisation. La matrice porte "trop" de directions d'incertitude. Si l'on supprime brutalement les colonnes excédentaires, on sous-estime drastiquement la variance *a posteriori*. Pour condenser cette information sans la perdre, on recourt à une méthode de **rééchantillonnage optimal** (Evensen, 2006). On génère d'abord un échantillon massif de  $N_{\text{samp}}$  membres ( $N_{\text{samp}} \gg N$ ) tirés selon la loi  $\mathcal{N}(0, P_X^a)$ . En appliquant une SVD sur ce large échantillon et en le projetant via une matrice orthonormale tronquée, on compresse l'information statistique dans une nouvelle matrice d'anomalies  $R_X \in \mathbb{R}^{n \times N}$  :

$$x_i^a = \hat{\mu}^a + [R_X]_i \quad \forall i \in \{1, \dots, N\} \quad (55)$$

### Cas 3 : Concordanance parfaite ( $r_\Sigma = N$ )

Dans ce cas idéal, la matrice racine possède naturellement le bon nombre de colonnes. La mise à jour de l'ensemble se fait de manière directe, en additionnant la nouvelle moyenne et la  $i$ -ème colonne de la racine de la covariance :

$$x_i^a = \hat{\mu}^a + \sqrt{N-1} \left[ \tilde{U} \tilde{\Sigma}^{1/2} \right]_i \quad \forall i \in \{1, \dots, N\} \quad (56)$$

Une fois ces  $N$  nouveaux états analysés construits, ils sont réinjectés dans le modèle dynamique NPZ pour entamer le pas de temps suivant (l'étape de prévision). Le cycle d'assimilation du KETKF est ainsi complet.

#### 5.3.5 Synthèse : Algorithme global de l'étape d'analyse KETKF

L'ensemble des étapes mathématiques détaillées précédemment peut se synthétiser sous la forme d'un algorithme opérationnel (Algorithme 1). Celui-ci fait appel à des sous-routines de gestion de rang (Algorithmes 2 et 3) selon la dimension de la covariance analytique générée.

**Algorithm 1** Étape d'analyse du KETKF

---

```

1: Entrées :  $E^f$  (Ensemble prévu),  $y$  (Observations),  $R$  (Covariance d'erreur d'obs.)
2:  $\tilde{H} \leftarrow R^{-1/2} H X^f$ 
3:  $e_d \leftarrow R^{-1/2} (y - H \hat{\mu}^f)$ 
4: Calculer la matrice de Gram  $K$  (et ses blocs  $K_X, K_H, K_{XH}$ ) selon le noyau choisi
5: Calculer l'EVD de l'espace observé :  $K_H = U_H \Sigma_H U_H^T$  avec  $\Sigma_H = \text{diag}(\lambda_1, \dots, \lambda_p)$ 
6:  $\alpha_H^* \leftarrow [(N-1)I_p + K_H]^{-1} e_d$ 
7:  $\hat{\mu}^a \leftarrow \hat{\mu}^f + K_{XH}^T \alpha_H^*$ 
8:  $P_X^a \leftarrow \frac{1}{N-1} \left[ K_X - K_{XH} U_H \text{diag} \left( \frac{1}{(N-1)+\lambda_i} \right) U_H^T K_{XH}^T \right]$ 
9: Calculer la SVD de la covariance d'état :  $P_X^a = U \Sigma V^T$ 
10: Tronquer  $\Sigma$  à son rang  $r_\Sigma$  (conservation des valeurs propres  $> 0$ ) pour obtenir  $\tilde{\Sigma}$ 
11:  $\tilde{U} \leftarrow$  les  $r_\Sigma$  premières colonnes de  $U$ 
12:  $R_X \leftarrow \tilde{U} \tilde{\Sigma}^{1/2} \triangleright$  Matrice racine de base
13: if  $r_\Sigma < N$  then
14:   for  $i = 1$  to  $N - r_\Sigma$  do
15:      $R_X \leftarrow \text{Rotation\_Farchi\_Bocquet}(R_X, i) \triangleright$  Voir Algorithme 2
16:   end for
17:    $E^a \leftarrow \hat{\mu}^a + \sqrt{N-1} R_X$ 
18: else if  $r_\Sigma > N$  then
19:    $R_X \leftarrow \text{Reechantillonnage\_Evensen}(R_X) \triangleright$  Voir Algorithme 3
20:    $E^a \leftarrow \hat{\mu}^a + R_X$ 
21: else
22:    $E^a \leftarrow \hat{\mu}^a + \sqrt{N-1} R_X \triangleright$  Cas idéal où  $r_\Sigma = N$ 
23: end if
24: return  $E^a$  (Ensemble analysé mis à jour)

```

---

**Algorithm 2** Étape de rotation de  $R_X$  (Farchi & Bocquet 2019)

---

```

1: Entrée :  $i \in \{1, \dots, N - r_\Sigma\}$  (indice de la boucle)
2: Entrée :  $R_X \in \mathbb{R}^{n \times r}$  (matrice à augmenter d'une colonne, avec  $r = r_\Sigma + i - 1$ )
3:  $\epsilon \leftarrow 1.0$ 
4:  $q \leftarrow r_\Sigma + i$ 
5:  $\theta \leftarrow \frac{\sqrt{q}}{\sqrt{q}-\epsilon}$ 
6: Construire la matrice de rotation spécifique  $Q_\epsilon \in \mathbb{R}^{q \times q}$  :

```

$$Q_\epsilon \leftarrow -\frac{\theta}{q} \begin{bmatrix} \frac{\epsilon\sqrt{q}}{-\theta} & \dots & \dots & \dots & \frac{\epsilon\sqrt{q}}{-\theta} \\ \vdots & \frac{q}{\theta} - 1 & -1 & \dots & -1 \\ \vdots & -1 & \ddots & \dots & \vdots \\ \vdots & \vdots & \dots & \frac{q}{\theta} - 1 & -1 \\ \frac{\epsilon\sqrt{q}}{-\theta} & -1 & \dots & -1 & \frac{q}{\theta} - 1 \end{bmatrix}$$

```

7:  $W \leftarrow [0_n \ R_X] \in \mathbb{R}^{n \times q} \triangleright$  Concaténation d'un vecteur nul
8:  $R_X \leftarrow W Q_\epsilon$ 
9: return  $R_X$  (Matrice augmentée d'une colonne, variance préservée)

```

---

**Algorithm 3** Rééchantillonnage de  $R_X$  (Evensen 2006)

---

```

1: Entrées :  $\tilde{U} \in \mathbb{R}^{n \times r_\Sigma}$  et  $\tilde{\Sigma} \in \mathbb{R}^{r_\Sigma \times r_\Sigma}$  (éléments de la SVD de  $P_X^a$ )
2: Paramètre :  $r_{\text{samp}}$  (facteur de sur-échantillonnage, ex : 100)
3:  $N_{\text{samp}} \leftarrow r_{\text{samp}} \times r_\Sigma$ 
4: Générer  $O \in \mathcal{O}(N_{\text{samp}}, \mathbb{R})$  une matrice aléatoire orthogonale
5: Générer  $\tilde{A} = [x_1, \dots, x_{N_{\text{samp}}}] \in \mathbb{R}^{n \times N_{\text{samp}}}$  avec  $x_i \sim \mathcal{N}(0, \tilde{U}\tilde{\Sigma}\tilde{U}^T)$ 
6: Construire la matrice de centrage  $M = I_{N_{\text{samp}}} - \frac{1}{N_{\text{samp}}} \mathbf{1}\mathbf{1}^T \in \mathbb{R}^{N_{\text{samp}} \times N_{\text{samp}}}$ 
7:  $\tilde{A} \leftarrow \tilde{A}M$   $\triangleright$  Centrage de l'échantillon massif
8: if  $r_{\text{samp}} > 1$  then
9:   Calculer la SVD :  $\tilde{A} = U_{\text{samp}}\Sigma_{\text{samp}}V_{\text{samp}}^T$ 
10:   $\tilde{O} \leftarrow O[1 : N, 1 : r_\Sigma]^T$   $\triangleright$  Troncature de la matrice orthogonale
11:  for  $j = 1$  to  $r_\Sigma$  do
12:     $[U_{\text{samp}}]_j \leftarrow \sqrt{\frac{1}{r_{\text{samp}}}} \times [\Sigma_{\text{samp}}]_{j,j} \times [U_{\text{samp}}]_j$ 
13:  end for
14:  Construire la matrice de centrage cible  $\tilde{M} = I_N - \frac{1}{N} \mathbf{1}\mathbf{1}^T \in \mathbb{R}^{N \times N}$ 
15:   $R_X \leftarrow \tilde{U}_{\text{samp}}\tilde{O}\tilde{M}$   $\triangleright$  Compression vers  $N$  membres
16: else
17:   $R_X \leftarrow \tilde{A}[1 : n, 1 : N]$ 
18: end if
19: return  $R_X$ 

```

---

*Note d'implémentation : Dans le cas où la matrice de Gram  $K$  est non-inversible, le calcul analytique repose sur sa pseudo-inverse (calculée numériquement via SVD). Cependant, sa dimension étant très faible (au maximum  $n + p$ ), ce calcul reste peu coûteux.*

## 6 Expériences numériques

### 6.1 Modèle de Lorenz 63

Avant d'évaluer le comportement du KETKF sur le modèle biogéochimique NPZ, il est classique de valider son implémentation sur un modèle "jouet" chaotique. Le modèle de Lorenz 63 est un modèle simplifié de convection atmosphérique (système d'équations différentielles ordinaires à 3 variables) extrêmement utilisé en assimilation de données pour tester la robustesse des filtres face à la non-linéarité et au chaos.

Le système est régi par les équations suivantes :

$$\begin{cases} \frac{dx}{dt} = \sigma(y - x) \\ \frac{dy}{dt} = \rho x - y - xz \\ \frac{dz}{dt} = xy - \beta z \end{cases} \quad (57)$$

Les non-linéarités proviennent des termes croisés  $xz$  et  $xy$ .

### 6.2 Expériences

Dans un premier temps, l'algorithme KETKF a été validé sur le modèle de Lorenz-63. Bien que de faible dimension ( $M = 3$ ), ce système présente une dynamique fortement non-linéaire et chaotique. Les expériences ont démontré que l'approche par méthode à noyau (RKHS) parvient à suivre la trajectoire de l'état, validant ainsi la capacité de l'algorithme à traiter de fortes non-linéarités locales sans diverger.

### 6.3 Le fléau de la dimension : Analyse sur le Lorenz-96

Afin d'évaluer le passage à l'échelle de la méthode, le filtre a ensuite été appliqué au modèle de Lorenz-96 configuré avec  $M = 40$  variables. Le système a été observé partiellement (une variable sur deux) avec une fréquence et un bruit d'observation fixes.

Les résultats mettent en évidence la robustesse des méthodes linéaires globales face à la dimension, avec une erreur d'analyse (RMSE) stable pour l'EnKF classique (RMSE  $\approx 0.16$ ). En revanche, l'application du KETKF *global* (sans technique de localisation spatiale) subit le fléau de la dimension (Curse of Dimensionality), conduisant à une perte totale de la trace (RMSE  $\approx 5$ ).

Ce phénomène s'explique par la nature du calcul dans l'espace des noyaux. Par exemple, pour un noyau RBF (Gaussien), l'augmentation de la dimension de l'espace d'état entraîne une croissance quadratique des distances Euclidiennes  $\|\mathbf{x} - \mathbf{y}\|^2$ . La matrice de Gram tend vers la matrice identité. Le filtre perçoit alors les membres de l'ensemble comme totalement décorrélés et devient aveugle aux observations. L'utilisation de noyaux non bornés, tels que le noyau polynomial, mène quant à elle à des instabilités numériques majeures (dépassement de capacité et mauvais conditionnement de l'inversion matricielle), nécessitant l'introduction d'une forte régularisation de Tikhonov :

$$M_{reg} = M_{inv} + \epsilon \mathbf{I} \quad (58)$$

Ces résultats confirment que pour des systèmes de grande dimension ( $M \gg 10$ ), les méthodes à noyau nécessitent obligatoirement l'implémentation d'une localisation spatiale pour rester opérationnelles.

## 7 Méthodo expériences

Spinup : Simulation sans assimilation du modèle NPZ sur une période de 5 ans, à partir de l'état initial exact  $\mathbf{x}_0$ .

Génération de la Vérité : Simulation du modèle NPZ sur une période d'un an, à partir de l'état équilibré après spinup.

Simulation des Observations : Ajout d'un bruit gaussien à la "Vérité" pour simuler des erreurs de mesure

Assimilation : Utilisation du filtre KETKF pour minimiser l'écart entre les membres de l'ensemble et les observations simulées.