



Rapport de Stage

BALOT Louise

21 Juillet 2026

IRIT - APO

Table des matières

1	Assimilation de données	2
1.1	Définition des variables et des espaces	2
2	Implémentation KETKF	2
2.1	Différents noyaux	2
2.2	Assimilation	2
2.3	Rotation	3
2.4	Rééchantillonnage	3
3	Expériences numériques	3
3.1	Modèle du Lorenz 63	3
3.2	Modèle du Lorenz-96	4
4	Implémentation NPZ 0D	5
4.1	Résultat des expériences	6
5	Implémentation NPZ 1D	6
5.1	Spinup	7
5.2	Troncature et Transformation Log-Exp	7
5.3	Résultats	7
5.3.1	Les 15 meilleures configurations en termes de RMSE	7
5.3.2	Comparaison des meilleures configurations par type de filtre	8
5.3.3	Surface et Moyenne	8
5.3.4	RMSE et rang	10
5.3.5	Effet sur le rang de K	10
6	Estimation de paramètres	11
6.1	Résultats avec m_P , m_Z et β	11
7	Conclusion	13

1 Assimilation de données

L'assimilation de données est une méthode "prédicteur/correction". Une prévision, calculée au pas de temps précédent et valable à l'instant considéré, est utilisée comme prédicteur. Les observations disponibles permettent de corriger cette ébauche pour estimer au mieux l'état réel du système étudié.

1.1 Définition des variables et des espaces

- **L'espace d'état (dimension n)** : Il contient tous les vecteurs liés à la physique du modèle numérique. La dimension n est définie par (Nombre de variables $\times$ Nombre de points de grille).
- **L'espace des observations (dimension p)** : Il contient les informations issues des capteurs (satellites, bouées, etc.). On a généralement $p \ll n$.

On fait également l'hypothèse classique que les erreurs du modèle et des instruments sont décorréliées ($\mathbb{E}[e_t e_0^T] = 0$).

2 Implémentation KETKF

2.1 Différents noyaux

Afin d'implémenter l'algorithme du Kernel ETKF comme présenté dans la thèse de Sophie Mauran, les noyaux suivants ont été définis :

- **Linéaire** : $K(x, y) = x^T y$
- **Polynomial** : $K(x, y) = (1 + x^T y)^d$
- **Sigmoïde** : $K(x, y) = \tanh(c \times x^T y)$
- **Hyperbolique** : $K(x, y) = \phi_{\text{Poincaré}}(x)^T \phi_{\text{Poincaré}}(y)$
avec $\phi_{\text{Poincaré}}(x) = x \times \frac{\text{arctanh}(c_{\text{boule}})}{c_{\text{norm}}}$ tel que $c_{\text{norm}} = \sqrt{c} \times \|x\|$ et c_{boule} la valeur de c_{norm} tronquée pour rester dans la boule unité.
- **RBF** : $K(x, y) = \exp\left(-\frac{\|x-y\|^2}{2\sigma^2}\right)$
- **RBF-exp** : $K(x, y) = \exp\left(-\frac{\|x-y\|}{\sigma}\right)$
- **Laplacien** : $K(x, y) = K_{\text{lin}}(x, y) \times K_{\text{cos}}(x, y)$
avec $K_{\text{cos}}(x, y) = \exp\left(\frac{-1}{\sqrt{N-1}} \times (1 - \cos^2(\theta))\right)$ et $\cos(\theta) = \frac{x^T y}{\|x\|\|y\|}$

en utilisant un scaler permettant de remettre toutes les variables sur une même échelle, pour les noyaux basés sur la distance.

2.2 Assimilation

L'assimilation commence par le tirage de N membres autour de l'état initial, avec une variance fixée par le modèle. On lance ensuite le calcul des statistiques de l'ensemble. Les observations sont obtenues à partir d'un échantillonnage du modèle vérité.

Chaque ensemble est projeté dans l'espace observé ; si demandé, on applique ensuite la transformation logarithmique. On construit la matrice de covariance de l'erreur d'observation R , puis sa décomposition en valeurs propres.

L'état est ensuite augmenté (variables d'état + variables observées), ce qui donne une matrice de taille $(n+p) \times N$. Le noyau est calculé à partir de cet ensemble, ce qui permet de récupérer le rang de la matrice de Gram K .

On détermine ensuite les coefficients α_H ainsi que la régularisation de Tikhonov. L'algorithme poursuit avec le calcul de la racine carrée de la covariance d'analyse PX_a .

Selon la valeur du rang r_Σ par rapport au nombre de membres N , une rotation mathématique (méthode Farchi–Bocquet) est appliquée pour redistribuer correctement les perturbations autour de la moyenne analysée μ_a .

Enfin, on revient dans l'espace physique : passage en exponentielle ou en version tronquée, selon les options choisies.

2.3 Rotation

Lorsque $r_\sigma < N$, on utilise la rotation de Farchi–Bocquet. L'objectif est de retrouver un rang égal à N en réintroduisant de la diversité dans l'ensemble via une rotation orthogonale.

La rotation déterministe de la thèse peut parfois dupliquer des membres, donc on applique une rotation aléatoire, basée sur une matrice orthogonale générée par $genOG_1$.

2.4 Rééchantillonnage

Dans le cas $r_\sigma > N$, on applique le rééchantillonnage d'Evensen (méthode de la thèse). Le rang est trop élevé : on sélectionne alors les directions principales pour revenir à un ensemble de rang N .

3 Expériences numériques

3.1 Modèle du Lorenz 63

Avant d'évaluer le comportement du KETKF sur le modèle biogéochimique NPZ, nous voulions valider son implémentation sur un premier modèle chaotique. Le modèle de Lorenz 63 est un modèle simplifié de convection atmosphérique, utilisé en assimilation de données pour tester la robustesse des filtres face à la non-linéarité et au chaos.

Le système est régi par les équations suivantes :

$$\begin{cases} \frac{dx}{dt} = \sigma(y - x) \\ \frac{dy}{dt} = \rho x - y - xz \\ \frac{dz}{dt} = xy - \beta z \end{cases} \quad (1)$$

Les non-linéarités proviennent des termes croisés xz et xy .

Expériences

Sachant que la RMSE globale présentée dans nos résultats est obtenue en calculant d'abord l'erreur quadratique moyenne sur l'ensemble des variables du modèle à chaque pas de temps, puis en effectuant la moyenne temporelle de ces erreurs sur toute la durée de la simulation, les résultats obtenus sont les suivants :

Méthode	RMSE moyen	RMSE std	RMV moyen	Temps moyen (s)
KETKF-lap	0.631781	0.077644	0.640131	4.216148
KETKF-polynomial	0.643361	0.026169	0.741729	4.108766
KETKF-hyperbolique	0.867793	0.227597	0.577236	4.237567
EnKF-Sqrt	0.882226	0.248140	0.586571	4.169060
KETKF-linear	0.882272	0.261050	0.574672	4.150521
KETKF-rbf	7.726832	0.960577	0.450688	4.160422
KETKF-rbf_exp	8.191577	0.935848	0.454661	4.146349
KETKF-sigmoid	10.769121	0.359256	0.001049	4.138241

TABLE 1 – Résultats moyennés sur 20 simulations ($N = 5$, inflation = 1.02).

Méthode	RMSE moyen	RMSE std	RMV moyen	Temps moyen (s)
EnKF-Sqrt	0.559945	0.015666	0.653259	4.563635
KETKF-linear	0.560062	0.029020	0.630088	6.561322
KETKF-lap	0.565614	0.023165	0.668232	6.648004
KETKF-hyperbolique	0.575384	0.063499	0.634079	6.626356
KETKF-polynomial	0.591305	0.024828	0.703600	6.530831
KETKF-rbf_exp	9.871239	0.229464	0.262811	6.617778
KETKF-rbf	9.897844	0.279158	0.261740	6.656781
KETKF-sigmoid	10.801589	0.352540	0.001048	6.538332

TABLE 2 – Résultats moyennés sur 10 simulations ($N = 15$, inflation = 1.02).

Nous pouvons observer des performances similaires entre le filtre ETKF codé dans la librairie *Dapper* (ici noté EnKF-Sqrt), et le kernel ETKF avec noyau linéaire. Les deux filtres étant théoriquement identiques, ils le sont ici expérimentalement.

De plus, nous pouvons affirmer que certains noyaux ne sont pas adéquats pour des systèmes tels que le Lorenz-63, comme le *rbf*, *rbf_exp* et *sigmoid*; mais aussi que d'autres noyaux comme le noyau *laplacien* montrent des performances en termes de RMSE au moins aussi bonne que l'ETKF de référence.

3.2 Modèle du Lorenz-96

Afin d'évaluer le passage à l'échelle de la méthode, le filtre a ensuite été appliqué au modèle de Lorenz-96 configuré avec $N = 40$ membres.

Les résultats trouvés ont été :

Méthode	RMSE moyen	RMSE std	RMV moyen	Temps moyen (s)
EnKF-Sqrt	0.080937	0.002712	0.096359	2.300211
KETKF-lap	0.130886	0.005774	0.116019	1.998810
KETKF-polynomial	0.151027	0.006612	0.163255	1.880589
KETKF-linear	1.232698	1.112295	0.080872	1.871018
KETKF-hyperbolique	1.888162	0.742178	0.082949	1.924863
KETKF-rbf_exp	2.890714	0.132510	0.160193	2.033277
KETKF-rbf	2.938618	0.154421	0.160202	2.024511
KETKF-sigmoid	4.785077	0.114417	0.001016	1.977595

TABLE 3 – Résultats moyennés sur 10 simulations ($N = 40$, inflation = 1.02).

4 Implémentation NPZ 0D




FIGURE 1 – Modèle NPZ 0D simulé sur 2 cycles sans assimilation

Une première implémentation du modèle Nutriments-Phytoplancton-Zooplancton a reposé sur une simulation de cycles saisonniers, avec des concentrations en nutriments, phytoplancton et zooplancton évoluant selon les équations :

$$\begin{cases} dN = -\mu_P \times P + \gamma_Z \times Z + m_P \times P + m_Z \times Z + (1 - \beta) \times g_Z \times Z \\ dP = \mu_P \times P - g_Z \times Z - m_P \times P \\ dZ = \beta \times g_Z \times Z - m_Z \times Z - \gamma_Z \times Z \end{cases} \quad (2)$$

avec les paramètres suivants :

$$\left\{ \begin{array}{ll} \mu_{max} = 0.9 & \text{taux croissance max phytoplancton} \\ K_N = 0.5 & \text{gradualité de la croissance des nutriments} \\ g_{max} = 1.0 & \text{taux broutage max zooplancton} \\ K_P = 1.0 & \text{influence prédation phytoplancton} \\ m_P = 0.07 & \text{taux mortalité linéaire phytoplancton} \\ m_Z = 0.07 & \text{taux mortalité linéaire zooplancton} \\ \beta = 0.5 & \text{efficacité assimilation zooplancton (transformé en biomasse)} \\ \gamma_Z = 0.05 & \text{taux excrétion, recyclage nutriments par zooplancton} \\ \mu_P = \mu_{saison} \times N / (K_N + N) & \text{Croissance phytoplancton} \\ g_Z = g_{max} \times P / (K_P + P) & \text{Croissance zooplancton} \end{array} \right. \quad (3)$$

et un état initial de concentrations : $N_0 = 10, P_0 = 0.1, Z_0 = 0.1$

4.1 Résultat des expériences

Méthode	RMSE moyen	RMSE std	RMV moyen	Temps moyen (s)
EnKF-Sqrt	0.020711	0.006568	0.066578	6.906506
KETKF-lap	0.101987	0.005459	0.102734	8.413607
KETKF-hyperbolique	0.102941	0.008246	0.054779	8.367076
KETKF-linear	0.108430	0.029914	0.054294	8.182638
KETKF-sigmoid	2.829957	0.079206	0.000991	8.190591
KETKF-polynomial	13.214756	26.605214	1.535811	8.214105
KETKF-rbf	789.008530	83.842069	0.338912	8.406351
KETKF-rbf_exp	869.330920	120.620421	0.339042	8.345693

TABLE 4 – Résultats moyennés sur 20 simulations ($N = 8$, inflation = 1.02).

5 Implémentation NPZ 1D




FIGURE 2 – Modèle NPZ 1D simulé pendant 5 ans sans assimilation

Afin de rendre la simulation plus réaliste, nous avons simulé le modèle NPZ en 1D, sur une colonne d'eau. De nombreux paramètres ont donc été rajoutés à ceux déjà existants en 3 :

$$\left\{ \begin{array}{ll}
 depth = 200 & \text{Profondeur totale colonne d'eau (m)} \\
 M = 20 & \text{Nombre de couches} \\
 d_z = depth/M & \text{Epaisseur couche} \\
 k_{ext} = 0.02 & \text{Coefficient d'atténuation de la lumière} \\
 z_{levels} & \text{Vecteur de profondeur de chaque couche} \\
 P_{seuil} = 0.1 & \text{Seuil de broutage} \\
 N_{deep} = 10.0 & \text{Réserve infinie de nutriments au fond} \\
 K_{zb} = 0.1 & \text{Diffusion au fond (stratifié, calme)} \\
 K_{z0} = 10.0 & \text{Diffusion en surface (brassé par le vent)} \\
 c_{therm} = 5.0/depth & \text{Finesse de la thermocline (couche de mélange)}
 \end{array} \right. \quad (4)$$

Les données des concentrations sont désormais stockées pour chaque z de la colonne d'eau, et sont soumises aux mêmes équations 2 du modèle 0D.

la propagation de la lumière dépend de l'*auto-ombrage*, basé sur le calcul de la biomasse cumulée dans les couches supérieures.

L'algorithme $step_{1D}$ calcule un pas de temps complet du modèle, sans matrice de diffusion, en appliquant directement les différences finies explicites avec conditions de Dirichlet au fond de l'océan, à partir de coefficients de diffusion.

5.1 Spinup

Pour que les expériences se déroulent au mieux, on réalise un spin-up, c'est-à-dire une phase de simulation de 5 ans sans assimilation, afin d'atteindre un état d'équilibre dynamiquement cohérent avec notre modèle physique NPZ. Cet état est ensuite stocké et chargé à chaque expérience, pour des conditions initiales optimales et identiques.

5.2 Troncature et Transformation Log-Exp

Le modèle NPZ est un modèle biologique qui calcule des concentrations. Ces valeurs doivent donc être positives. Cependant, les algorithmes de filtres de Kalman n'assurent pas de renvoyer des valeurs positives après assimilation. C'est pour cela que nous utilisons deux méthodes :

- **Troncature à zéro pour les valeurs négatives.** Cette méthode s'accompagne souvent de pertes d'information.
- **Transformation log-exp** : elle consiste à appliquer la fonction logarithme aux membres de l'ensemble au début de l'assimilation, puis à appliquer la fonction exponentielle à la sortie afin de ne récupérer que des valeurs positives. Aucune information n'est perdue, mais le passage à l'exponentielle peut faire gonfler les erreurs.

5.3 Résultats

Pour nos expériences, les résultats de 10 simulations ont été moyennés, avec $N = 55$ et en testant toutes les combinaisons de filtres avec les paramètres suivants : **inflation** $\in [1.001, 1.01, 1.05]$, **méthode de positivité** $\in [\text{'troncature'}, \text{'log transformation'}]$, **régression de Tikhonov** $\in [1e-4, 1e-3, 1e-2]$, **coefficient** $c_{tanh} \in [1e-4, 1e-3, 1e-2, 1e-1]$ et enfin le **degré** du noyau polynomial $\in [1, 2, 3]$.

5.3.1 Les 15 meilleures configurations en termes de RMSE

Ce tableau regroupe les 15 configurations ayant le RMSE moyen le plus faible.

Filtre	Paramètres	Positivité	RMSE moyen	RMSE std	RMV moyen
KETKF-hyperbolique	infl=1.001, c=0.0001, reg=0.0001	log_tr	4.70×10^{-2}	2.49×10^{-2}	1.24×10^{-2}
KETKF-linear	infl=1.01, reg=0.001	log_tr	5.02×10^{-2}	2.22×10^{-2}	1.48×10^{-2}
KETKF-hyperbolique	infl=1.001, c=0.001, reg=0.0001	log_tr	5.21×10^{-2}	2.66×10^{-2}	1.32×10^{-2}
KETKF-lap	infl=1.01, reg=0.01	log_tr	5.35×10^{-2}	1.64×10^{-2}	1.86×10^{-2}
KETKF-hyperbolique	infl=1.001, c=0.0001, reg=0.001	log_tr	5.44×10^{-2}	1.80×10^{-2}	8.73×10^{-3}
KETKF-hyperbolique	infl=1.001, c=0.01, reg=0.0001	log_tr	5.45×10^{-2}	3.12×10^{-2}	1.27×10^{-2}
KETKF-lap	infl=1.01, reg=0.0001	log_tr	5.53×10^{-2}	3.08×10^{-2}	1.74×10^{-2}
KETKF-linear	infl=1.01, reg=0.0001	log_tr	5.59×10^{-2}	1.73×10^{-2}	2.04×10^{-2}
KETKF-linear	infl=1.001, reg=0.001	log_tr	5.78×10^{-2}	2.63×10^{-2}	1.76×10^{-2}
KETKF-lap	infl=1.001, reg=0.001	log_tr	5.89×10^{-2}	2.52×10^{-2}	1.62×10^{-2}
KETKF-hyperbolique	infl=1.001, c=0.001, reg=0.001	log_tr	5.96×10^{-2}	2.26×10^{-2}	9.56×10^{-3}
KETKF-hyperbolique	infl=1.01, c=0.0001, reg=0.001	log_tr	6.06×10^{-2}	3.05×10^{-2}	1.58×10^{-2}
KETKF-lap	infl=1.001, reg=0.01	log_tr	6.22×10^{-2}	4.87×10^{-2}	1.44×10^{-2}
EnKF-PertObs	infl=1.001, rot=False	trunc	6.28×10^{-2}	3.31×10^{-2}	0.1076
KETKF-lap	infl=1.05, reg=0.001	log_tr	6.30×10^{-2}	2.24×10^{-2}	1.60×10^{-2}

TABLE 5 – Les 15 meilleures configurations globales triées par RMSE moyen croissant.

On peut ainsi voir que la log-transformation apporte de meilleurs résultats en termes de RMSE que la troncature à 0, et que le noyau hyperbolique semble être particulièrement adéquat pour ce modèle.

5.3.2 Comparaison des meilleures configurations par type de filtre

Ce tableau isole la meilleure configuration pour chaque type de filtre testé, permettant de comparer directement les performances maximales des différents noyaux face à la méthode classique d'ensemble.

Filtre (Meilleur)	Paramètres optimaux	Positivité	RMSE moyen	RMSE std	RMV moyen
KETKF-hyperbolique	infl=1.001, c=0.0001, reg=0.0001	log_tr	4.70×10^{-2}	2.49×10^{-2}	1.24×10^{-2}
KETKF-linear	infl=1.01, reg=0.001	log_tr	5.02×10^{-2}	2.22×10^{-2}	1.48×10^{-2}
KETKF-lap	infl=1.01, reg=0.01	log_tr	5.35×10^{-2}	1.64×10^{-2}	1.86×10^{-2}
EnKF-PertObs	infl=1.001, rot=False	trunc	6.28×10^{-2}	3.31×10^{-2}	0.1076
KETKF-sigmoid	infl=1.01, c=0.001, reg=0.001	log_tr	6.79×10^{-2}	3.23×10^{-2}	1.76×10^{-2}
EnKF-DEnKF	infl=1.001	trunc	7.37×10^{-2}	2.98×10^{-2}	0.1095
EnKF-Sqrt	infl=1.001	trunc	7.59×10^{-2}	3.80×10^{-2}	0.1072
KETKF-rbf	infl=1.05, reg=0.001, sigma=0.5	log_tr	2.44	4.33×10^{-2}	0.7836
KETKF-rbf_exp	infl=1.05, reg=0.0001, sigma=0.5	log_tr	2.45	4.91×10^{-2}	0.7850
KETKF-polynomial	infl=1.05, reg=0.001, deg=3	log_tr	4.88	5.30×10^{-2}	0.3271

TABLE 6 – Meilleure configuration pour chaque méthode, triée par RMSE moyen croissant

5.3.3 Surface et Moyenne




FIGURE 3 – Couche surfacique du modèle NPZ 1D simulé pendant 1 an sans assimilation, puis 2 ans avec assimilation (N=55, paramètres optimaux 6)




FIGURE 4 – Moyenne verticale du modèle NPZ 1D simulé pendant 1 an sans assimilation, puis 2 ans avec assimilation ($N=55$, paramètres optimaux 6)

Les figures 3 et 4 illustrent la dynamique biogéochimique du modèle NPZ. Le cycle des saisons est bien observé :

- **En hiver**, le brassage vertical remonte les nutriments (N) depuis les profondeurs vers la surface. Cependant, le manque de lumière (atténuation k_{ext}) limite la photosynthèse, maintenant la concentration en phytoplancton (P) à un niveau très bas.
- **Au printemps**, l'augmentation de l'ensoleillement déclenche le bloom printanier : le phytoplancton consomme massivement les nutriments en surface et se développe.
- **En été**, les nutriments en surface s'épuisent et le broutage des zooplanctons (Z) entraîne une chute de la concentration en phytoplancton, jusqu'au prochain brassage hivernal.

De plus, le passage du modèle physique seul durant la première année, à l'assimilation de données à partir de la deuxième année ne perturbe pas significativement les résultats, et ne génère pas de valeurs numériques aberrantes.

5.3.4 RMSE et rang




FIGURE 5 – RMSE de chaque paramètre N, P et Z en fonction du temps, simulé à partir des filtres en conditions optimales trouvées en 6

La figure 5 confirme l'efficacité des différents filtres utilisés. En effet, on remarque que l'erreur n'est pas constante dans le temps : elle subit des pics lors des périodes de bloom printanier. Ces pics s'expliquent par la très forte non-linéarité des équations de croissance du phytoplancton (2). Néanmoins, l'assimilation parvient tout de même à ramener l'erreur vers zéro, prouvant la capacité des filtres à corriger la trajectoire du modèle même lors de transitions chaotiques brutales.

5.3.5 Effet sur le rang de K




FIGURE 6 – Évolution du rang des matrices de Gram associées à chaque noyau en fonction du temps

Sur cette figure, nous pouvons voir que le rang de la matrice de Gram calculé par le noyau varie au fur et à mesure du cycle. En hiver, la dynamique du modèle est assez calme, puis s'intensifie largement lors du bloom printanier. Ainsi, le rang baisse en hiver et remonte au printemps.

De plus, le rang de la plupart des noyaux est plafonné à 54. Ceci est dû au fait que dans la formulation du filtre, la matrice des anomalies X_f possède une somme nulle par construction, puisque ses colonnes sont centrées sur la moyenne de l'ensemble. Par conséquent, les membres de l'ensemble évoluent dans un sous-espace vectoriel dont la dimension maximale est strictement bornée à $N - 1 = 54$.

Pour le noyau *hyperbolique*, la normalisation géométrique (boule de Poincaré) agit comme une pondération sur les vecteurs d'état. Cette opération préserve les colinéarités et maintient le rang bloqué à 54. Quant au noyau *sigmoïde*, bien qu'il soit non linéaire, l'utilisation d'un faible coefficient d'échelle ($c = 0.001$) restreint la fonction $\tanh$ à une fonction quasi-linéaire, poussant le rang maximal à 55.

Cependant, le noyau *laplacien* mène à un rang allant jusqu'à 58. Celui-ci repose sur une fonction exponentielle de la distance, il projette donc l'information de l'ensemble dans un espace de dimension infinie, brisant la contrainte de la somme nulle. Mais le rang reste toujours plafonné à 60, car il est borné par le nombre de paramètres (3 paramètres N,P,Z $\times$ 20 couches).

6 Estimation de paramètres

L'estimation de paramètres consiste à augmenter la taille du vecteur d'état en y incluant les paramètres à estimer. Cela permet d'utiliser les mêmes algorithmes d'assimilation qu'auparavant, en maintenant les paramètres constants lors de l'étape de prévision. De plus, une transformation logarithmique est appliquée aux paramètres afin de garantir des valeurs physiques positives.

6.1 Résultats avec m_P , m_Z et β

Filtre (N=55)	Paramètres optimaux	Positivité	RMSE État	RMSE Paramètres	RMV moyen	Temps (s)
EnKF-Sqrt	infl=1.001	trunc	2.78×10^{-3}	1.40×10^{-2}	6.91×10^{-3}	18.45
EnKF-PertObs	infl=1.001, rot=False	trunc	2.95×10^{-3}	1.46×10^{-2}	6.38×10^{-3}	16.83
EnKF-DEnKF	infl=1.001	trunc	3.24×10^{-3}	2.09×10^{-2}	6.91×10^{-3}	18.32
KETKF-linear	infl=1.01, reg=0.001	log_tr	3.73×10^{-2}	6.97×10^{-2}	5.50×10^{-3}	25.01
KETKF-lap	infl=1.01, reg=0.01	log_tr	4.19×10^{-2}	6.85×10^{-2}	5.68×10^{-3}	25.87
KETKF-hyperbolique	infl=1.001, c=0.0001, reg=0.0001	log_tr	3.77×10^{-2}	8.08×10^{-2}	5.39×10^{-3}	25.31
KETKF-sigmoid	infl=1.01, c=0.001, reg=0.001	log_tr	4.30×10^{-2}	6.66×10^{-2}	1.72×10^{-2}	25.15
KETKF-rbf_exp	infl=1.05, reg=0.0001, sigma=0.5	log_tr	6.34×10^{-2}	6.53×10^{-2}	5.66×10^{-1}	27.40
KETKF-rbf	infl=1.05, reg=0.001, sigma=0.5	log_tr	8.45×10^{-2}	6.53×10^{-2}	5.64×10^{-1}	26.16
KETKF-polynomial	infl=1.05, reg=0.001, deg=3	log_tr	4.90×10^{13}	3.32×10^5	2.54×10^{11}	25.04

TABLE 7 – Performances moyennes de l'estimation conjointe d'état et de paramètres pour N=55




FIGURE 7 – Statistiques RMSE, RMV et rang selon les filtres, avec estimation des trois paramètres m_P , m_Z et β

La table 7 et la figure 7 nous montrent que les filtres les plus efficaces en termes de RMSE lors de l'estimation conjointe d'états et paramètres sont les filtres EnKF classiques. En effet, leurs RMSE sont plus faibles pour les nutriments, le phytoplancton et le zooplancton, mais ces filtres semblent surtout être les seuls qui convergent vers la valeur correcte des paramètres m_P , m_Z et β .

Par ailleurs, du point de vue du coût de calcul, les méthodes à noyaux sont systématiquement moins rapides que les méthodes classiques, nécessitant la manipulation de lourdes matrices supplémentaires.

Enfin, le rang de la matrice de Gram est intéressant à observer. Pour les filtres *rbf* et *rbf_exp*, le rang atteint 123, tandis que celui du laplacien oscille entre 91 et 75, et que ceux des autres filtres sont majorés à 54.

7 Conclusion

Au cours de ce stage, nous avons implémenté et évalué la méthode d'assimilation de données KETKF (Kernel Ensemble Transform Kalman Filter) sur divers modèles.

Nos expériences sur les modèles chaotiques classiques de Lorenz (L63 et L96) ont d'abord permis de valider le comportement de notre algorithme de filtre à noyau, et de soulever des comportements sensibles au fléau de la dimension, particulièrement pour les noyaux RBF et polynomiaux.

L'application de la méthode aux modèles biogéochimiques NPZ (0D puis 1D) a constitué le cœur de notre étude. La prise en compte de la positivité des concentrations biologiques par une approche de transformation log-exp s'est avérée bien plus performante qu'une simple troncature. De plus, nos expériences ont révélé que le noyau hyperbolique, basé sur une géométrie de Poincaré, obtient de meilleures performances que les méthodes d'ensemble classiques (EnKF) et les autres noyaux en termes de précision d'analyse, atteignant un RMSE de l'ordre de 4.70×10^{-2} .

L'analyse de l'évolution du rang de la matrice de covariance lors des cycles saisonniers a également confirmé que les noyaux manipulent l'espace d'état différemment. Le noyau laplacien, en projetant les membres dans un espace de dimension infinie, permet de contourner la limitation de dimensionnalité ($N - 1$) propre à l'ETKF, permettant des résultats intéressants et proches du noyau hyperbolique.

Enfin, l'estimation conjointe d'état et de paramètres permet aux filtres d'ensemble classiques de prendre le dessus, offrant ainsi les meilleures performances et le meilleur coût de calcul.

Les voies d'amélioration seraient donc peut-être une localisation de la méthode afin d'obtenir de meilleurs résultats, notamment pour les noyaux RBF, ainsi qu'une inflation adaptative.